

S-Curt: MIR with TDA

DSP 기반 음악 특징 공간에 대한 위상적 음악 정보 검색 연구

Abstract

본 연구는 Music Information Retrieval(MIR)에서 전통적인 DSP 기반 feature vector 분석에 Topological Data Analysis(TDA)를 결합하여 음악 오디오 데이터의 구조적 특성을 분석하는 것을 목표로 한다. 연구 대상은 Apple Music에서 수집한 string quartet preview audio이며, 각 오디오 파일로부터 MFCC, spectral centroid, RMS energy, zero-crossing rate, chroma, onset strength 등의 DSP feature를 추출하였다. 이후 frame-level feature vector들을 point cloud 또는 graph로 해석하고, Vietoris-Rips complex, Betti number, persistent homology의 관점에서 음악의 구조를 요약하였다.

실험적으로 DSP baseline은 composer classification에서 높은 accuracy를 보였지만, class imbalance로 인해 Macro F1은 낮게 나타났다. 반면 TDA-only prototype은 standalone classifier로는 낮은 성능을 보였으나, 음악 feature space의 global structure를 설명하는 보조적 표현으로서 가능성을 보였다. 따라서 본 연구는 TDA를 DSP를 대체하는 방법이 아니라, DSP가 포착하지 못하는 음악적 구조와 반복성, feature-space geometry를 보완하는 방법으로 해석한다.

1 연구 배경

Music Information Retrieval(MIR)은 음악 데이터를 분석하여 장르 분류, 작곡가 분류, 음악 추천, 유사도 검색, 태깅 등의 문제를 해결하는 연구 분야이다. 일반적인 MIR 시스템은 오디오 신호에서 acoustic feature를 추출한 뒤, 이를 machine learning 또는 statistical model의 입력으로 사용한다.

전통적인 MIR feature는 대체로 DSP(Digital Signal Processing)에 기반한다. 예를 들어 MFCC는 음색 정보를, spectral centroid는 밝기, RMS energy는 에너지, zero-crossing rate는 신호의 거칠기, chroma는 pitch class 분포를 나타낸다. 이러한 feature들은 음악 신호의 local property를 정량화하는 데 강력하다.

그러나 DSP feature만으로는 음악의 global structure를 충분히 설명하기 어렵다. 특히 음악은 시간에 따라 변화하는 연속적인 구조이며, 반복, 회귀, 순환, 연결성, 클러스터 구조와 같은 형태적 특성을 가진다. 이러한 구조는 단순 평균, 분산, 최대값 등의 summary statistic만으로는 쉽게 포착되지 않는다.

이에 본 연구는 TDA(Topological Data Analysis)를 MIR에 적용한다. TDA는 데이터의 모양(shape)을 분석하는 수학적 방법이며, connected component, cycle, hole과 같은 위상적 구조를 통해 데이터의 global organization을 설명한다.

본 연구의 핵심 관점은 다음과 같다.

DSP는 음악 신호를 수치적 feature vector로 요약하고, TDA는 그 feature vector들이 이루는 공간의 구조를 분석한다.

즉, 본 연구는 DSP와 TDA를 경쟁 관계가 아니라 상호 보완 관계로 본다.

2 연구 질문

본 연구의 연구 질문은 다음과 같다.

RQ. DSP 기반 feature space에 TDA를 적용하면, string quartet audio excerpt의 음악적 구조를 의미 있게 분석할 수 있는가?

이를 더 구체적으로 나누면 다음과 같다.

- (1) DSP feature만으로 composer classification을 수행했을 때의 성능은 어떠한가?
- (2) TDA-only feature는 composer classification에서 어느 정도의 성능을 보이는가?
- (3) TDA는 DSP feature가 놓치는 global structure를 보완할 수 있는가?
- (4) 짧은 preview audio에서도 TDA 기반 구조 표현이 의미를 가질 수 있는가?

본 연구의 가설은 다음과 같다.

Hypothesis. TDA-only feature는 standalone classifier로는 DSP baseline보다 낮은 성능을 보일 수 있지만, feature space의 global structure를 포착하므로 DSP와 결합할 때 보조적 정보로 활용될 수 있다.

3 데이터

3.1 수집 대상

본 연구에서는 Apple Music에서 수집한 string quartet audio preview를 사용하였다. 총 데이터 수는 약 181개이며, 각 preview는 .m4a 형식으로 저장된 뒤 분석을 위해 .wav 파일로 변환되었다.

데이터의 domain은 다음과 같이 설정하였다.

- 음악 장르: Classical music
- 편성: String quartet
- 출처: Apple Music preview audio
- 분석 단위: short audio excerpt

3.2 Label 구성

Apple Music metadata에는 composer label이 명시적으로 제공되지 않는 경우가 있었다. 따라서 본 연구에서는 다음과 같은 textual metadata를 활용해 composer를 heuristic하게 추정하였다.

- song name
- albumName

- artistName
- searchQuery

분류 과제는 artist classification이 아니라 composer classification으로 설정하였다. 그 이유는 string quartet이라는 domain에서는 연주자보다 작곡가가 음악적 스타일 차이를 더 잘 설명할 수 있기 때문이다.

4 DSP Baseline

4.1 Feature Extraction

DSP baseline에서는 frame-level acoustic descriptor를 추출한 뒤, 이를 piece-level feature vector로 aggregation하였다. 사용된 대표 feature는 다음과 같다.

- MFCC
- Spectral centroid
- Spectral bandwidth
- Spectral rolloff
- RMS energy
- Zero-crossing rate
- Chroma
- Onset strength

이러한 feature들은 음악 신호의 timbre, brightness, energy, pitch-class distribution, rhythmic activity 등을 수치적으로 표현한다.

4.2 Representative Formulas

Spectral centroid는 주파수 성분의 중심을 나타내며 다음과 같이 정의된다.

$$C = \frac{\sum_f fX(f)}{\sum_f X(f)}. \quad (1)$$

여기서 $X(f)$ 는 주파수 f 에서의 magnitude spectrum이다. Spectral centroid가 클수록 신호는 더 밝은 음색을 갖는 경향이 있다.

RMS energy는 오디오 신호의 평균 에너지를 나타낸다.

$$RMS = \sqrt{\frac{1}{N} \sum_{n=1}^N x[n]^2}. \quad (2)$$

Zero-crossing rate는 신호가 0을 교차하는 빈도를 나타낸다.

$$ZCR = \frac{1}{N-1} \sum_{n=1}^{N-1} \mathbf{1}(\text{sign}(x[n]) \neq \text{sign}(x[n+1])). \quad (3)$$

4.3 DSP Baseline 결과

두 가지 DSP setting을 실험하였다.

Table 1: DSP baseline 결과

Method	Accuracy	Macro F1
Summary baseline	0.8827	0.2344
Sequential baseline	0.8827	0.2344

DSP baseline은 accuracy 측면에서는 높은 성능을 보였다. 그러나 Macro F1은 낮게 나타났다. 이는 dominant composer class에 대해서는 잘 맞추지만, minor composer class에 대해서는 성능이 낮다는 것을 의미한다.

Summary baseline과 sequential baseline의 결과가 동일하게 나타났다는 점도 중요하다. 이는 짧은 preview audio에서는 temporal ordering이 충분히 활용되지 못했거나, 현재 feature aggregation 방식이 시간적 정보를 충분히 반영하지 못했음을 시사한다.

5 Topological Data Analysis

5.1 TDA의 기본 아이디어

TDA는 데이터의 shape을 분석하는 방법이다. 일반적인 machine learning feature가 각 데이터 포인트의 수치값에 집중한다면, TDA는 데이터 포인트들이 전체적으로 어떤 구조를 이루는지 분석한다.

TDA에서 중요한 개념은 다음과 같다.

- Connected component: 서로 연결된 데이터 묶음
- Cycle: loop 또는 반복 구조
- Hole: 비어 있는 공간
- Filtration: scale parameter에 따라 complex를 점진적으로 확장하는 과정
- Persistent homology: 여러 scale에서 오래 유지되는 topological feature

음악 데이터에서는 이러한 구조가 다음과 같이 해석될 수 있다.

5.2 Point Cloud Construction

본 연구에서는 frame-level acoustic feature vector를 하나의 node 또는 point로 보았다. 각 time frame t 에 대해 다음과 같은 feature vector를 구성한다.

Table 2: TDA 개념의 음악적 해석

TDA Concept	Musical Interpretation
Connected component	유사한 acoustic state들의 cluster
Cycle	반복, 회귀, 순환적 feature transition
Persistent feature	noise에 덜 민감한 안정적 음악 구조
Point cloud geometry	음악 excerpt의 feature-space trajectory

$$z_t = [MFCC_1, \dots, MFCC_p, centroid, RMS, ZCR, onset, chroma]. \quad (4)$$

전체 오디오 excerpt는 다음과 같은 point cloud로 표현된다.

$$Z = \{z_1, z_2, \dots, z_T\}. \quad (5)$$

즉, 하나의 음악 excerpt는 시간에 따라 변화하는 acoustic state들의 집합으로 해석된다.

5.3 Vietoris–Rips Complex

Point cloud Z 가 주어졌을 때, scale parameter ϵ 에 대해 두 점 z_i, z_j 의 거리가 다음 조건을 만족하면 edge를 연결한다.

$$d(z_i, z_j) \leq \epsilon. \quad (6)$$

이러한 방식으로 구성된 complex를 Vietoris–Rips complex라고 한다. ϵ 이 작을 때는 가까운 점들만 연결되고, ϵ 이 커질수록 더 많은 점과 edge가 연결된다. 따라서 ϵ 의 변화에 따라 데이터의 topological structure가 변화한다.

5.4 Betti Numbers

Betti number는 topological feature의 개수를 나타낸다.

- β_0 : connected component의 개수
- β_1 : cycle 또는 loop의 개수
- β_2 : void 또는 cavity의 개수

본 연구에서는 주로 β_0 와 β_1 에 집중하였다. 짧은 오디오 preview와 낮은 차원의 feature representation에서는 고차 homology를 안정적으로 해석하기 어렵기 때문이다.

5.5 Cycle Proxy

Full persistent homology package를 사용하지 않는 대신, 본 연구의 MATLAB prototype에서는 coarse topological summary를 사용하였다. Connected component는 직접 계산하였고, cycle은 graph-theoretic proxy로 근사하였다.

$$\beta_0(\epsilon) = \text{number of connected components at scale } \epsilon. \quad (7)$$

$$\beta_1(\epsilon) \approx |E_\epsilon| - |V_\epsilon| + C_\epsilon. \quad (8)$$

여기서 $|E_\epsilon|$ 는 scale ϵ 에서의 edge 수, $|V_\epsilon|$ 는 vertex 수, C_ϵ 는 connected component 수이다. 이는 graph의 cycle rank에 해당하는 식이다.

6 Delay Embedding

TDA에서는 scalar time series를 직접 point cloud로 변환하기 위해 delay embedding을 사용할 수 있다. 스칼라 시계열 s_t 에 대해 delay embedding은 다음과 같이 정의된다.

$$y_t = [s_t, s_{t+\tau}, s_{t+2\tau}, \dots, s_{t+(m-1)\tau}]. \quad (9)$$

여기서 τ 는 delay parameter이고, m 은 embedding dimension이다.

음악 오디오에서는 onset strength, RMS energy, spectral centroid 등의 scalar series를 사용하여 delay embedding을 만들 수 있다. 이 경우 point cloud는 단순한 feature distribution이 아니라 시간적 변화의 trajectory를 반영하게 된다.

7 TDA Feature Vector

최종 TDA feature vector는 Betti curve와 MST 기반 통계를 요약하여 구성하였다.

$$f_{TDA} = \phi(\beta_0(\epsilon), \beta_1(\epsilon), \text{MST statistics}). \quad (10)$$

여기서 ϕ 는 여러 scale에서 얻은 topological summary를 classification에 사용할 수 있는 fixed-length vector로 변환하는 함수이다.

MST(Minimum Spanning Tree) 기반 통계는 point cloud의 연결 구조를 요약한다. 예를 들어 edge length의 평균, 분산, 최대값, 최소값 등을 사용할 수 있다.

8 TDA Baseline 결과

초기 TDA prototype의 결과는 다음과 같다.

Table 3: TDA baseline 결과

Method	Accuracy	Macro F1
Initial TDA prototype	0.1333	0.1191
pointcloud_pca2	0.1667	0.1519
pointcloud_centroid_onset	0.1167	0.1093
pointcloud_mfcc12	0.1500	0.1421

TDA-only prototype은 DSP baseline보다 낮은 성능을 보였다. 특히 accuracy가 낮게 나타났으며, 이는 current topological summary가 composer classification을 단독으로 수행하기에는 충분하지 않음을 의미한다.

그러나 TDA 실험은 중요한 의미를 가진다. pointcloud_pca2가 가장 높은 성능을 보였다는 점은 단순한 hand-crafted 2D coordinate보다 compact latent acoustic state space가 topological analysis에 더 안정적일 수 있음을 보여준다.

9 DSP와 TDA의 비교

DSP와 TDA는 음악 데이터를 바라보는 관점이 다르다.

Table 4: DSP와 TDA의 비교

Category	DSP	TDA
Input view	Signal as feature values	Signal as shape or structure
Main object	Feature vector	Point cloud / graph / complex
Information	Local acoustic property	Global structural property
Examples	MFCC, tempo, centroid	Betti curve, barcode, persistence
Strength	Strong classification baseline	Robust structural description
Weakness	Sensitive to feature aggregation	Weak alone with naive summaries

DSP baseline은 높은 accuracy를 보였지만 Macro F1이 낮았다. 이는 class imbalance 상황에서 majority class 중심으로 성능이 형성되었음을 의미한다.

TDA baseline은 classification 성능 자체는 낮았지만, 음악 feature space의 구조를 다른 방식으로 설명한다. 따라서 본 연구에서는 TDA를 DSP의 대체재가 아니라 DSP feature를 보완하는 구조적 representation으로 해석한다.

10 Evaluation Metric

본 연구의 데이터는 composer별 class imbalance가 존재한다. 따라서 accuracy만으로 모델 성능을 평가하는 것은 충분하지 않다.

Accuracy는 전체 샘플 중 맞춘 비율을 나타낸다.

$$Accuracy = \frac{\text{number of correct predictions}}{\text{number of total predictions}}. \quad (11)$$

그러나 majority class가 많은 경우, 모델이 majority class만 잘 맞춰도 높은 accuracy를 얻을 수 있다. 따라서 Macro F1을 함께 사용하였다.

$$MacroF1 = \frac{1}{K} \sum_{k=1}^K F1_k. \quad (12)$$

각 class에 대한 F1 score는 다음과 같다.

$$F1_k = \frac{2P_k R_k}{P_k + R_k}. \quad (13)$$

여기서 P_k 는 class k 의 precision, R_k 는 class k 의 recall이다. Macro F1은 각 class의 F1을 동일한 가중치로 평균내므로, minor class 성능을 더 잘 반영한다.

11 실험 결과 해석

본 연구의 주요 결과는 다음과 같다.

$$DSP : (Accuracy, MacroF1) = (0.8827, 0.2344). \quad (14)$$

$$Best\ TDA : (Accuracy, MacroF1) = (0.1667, 0.1519). \quad (15)$$

DSP baseline은 composer classification에서 높은 accuracy를 보였다. 그러나 Macro F1이 낮다는 점에서, composer별 균형 잡힌 분류 성능은 아직 부족하다.

TDA-only model은 낮은 accuracy를 보였다. 이는 현재의 naive TDA summary만으로는 짧은 preview audio의 composer를 분류하기 어렵다는 것을 의미한다. 특히 preview audio는 길이가 짧기 때문에 충분한 반복 구조나 장기적 음악 흐름이 드러나지 않을 수 있다.

그럼에도 불구하고 TDA 결과는 부정적인 결과만은 아니다. TDA pipeline이 end-to-end로 구현되었고, point cloud 구성 방식에 따라 성능 차이가 나타났기 때문이다. 이는 TDA의 성능이 어떤 feature space를 구성하느냐에 크게 의존한다는 점을 보여준다.

12 관련 연구

12.1 Topological Music Analysis

Alcalá-Alvarez와 Padilla-Longoria는 score의 vertical event를 기반으로 음악을 point cloud와 simplicial complex로 변환하는 TMA framework를 제안하였다. 이 연구는 pitch class, duration, onset, interval vector 등을 사용하여 음악 fragment를 여러 Euclidean space에 embedding하고, persistent homology와 bottleneck distance를 통해 음악 fragment 간의 구조적 차이를 분석하였다.

이 관점은 본 연구와 직접적으로 연결된다. 본 연구는 score가 아니라 audio feature space를 대상으로 하지만, 음악을 단순한 sequence가 아니라 topological object로 해석한다는 점에서 같은 흐름에 있다.

12.2 Persistent Homology와 CNN

Liu, Jeng, Yang은 persistence landscape를 CNN 구조에 결합한 Persistent Convolutional Neural Network(PCNN)를 제안하였다. 이 연구는 audio signal segment의 topological summary를 CNN feature와 결합하여 music auto-tagging 성능을 향상시켰다.

이는 본 연구의 향후 방향과 밀접하다. 현재 본 연구의 TDA는 standalone feature로 사용되었지만, 향후에는 DSP 또는 neural network feature와 결합하는 hybrid model로 확장할 수 있다.

12.3 Korean Music과 TDA

Tran, Park, Jung은 정간보로 기록된 한국 전통음악을 pitch-duration node graph로 변환하고, persistent homology를 통해 cycle structure를 분석하였다. 특히 도드리 음악에서는 cycle들이 서로 겹쳐 나타나며, 타령과 같은 비도드리 음악에서는 cycle들이 상대적으로 독립적으로 나타난다는 차이를 보였다.

또한 후속 연구에서는 overlap matrix를 이용하여 TDA 기반 machine composition 방법을 제안하였다. 이는 TDA가 단순 분석을 넘어 음악 생성 및 구조 모델링에도 활용될 수 있음을 보여준다.

13 연구의 의의

본 연구의 의의는 다음과 같다.

- (1) Apple Music preview audio를 활용하여 실제 MIR pipeline을 구성하였다.
- (2) DSP feature extraction부터 composer classification까지 baseline을 구축하였다.
- (3) TDA를 audio feature space에 적용하여 point cloud 기반 구조 분석을 시도하였다.
- (4) TDA-only model의 한계를 실험적으로 확인하였다.
- (5) 향후 DSP+TDA hybrid MIR system의 가능성을 제시하였다.

특히 본 연구는 성공적인 classification 결과만을 제시하는 것이 아니라, TDA가 어떤 조건에서 약하고, 어떤 방식으로 개선되어야 하는지를 확인했다는 점에서 의미가 있다.

14 한계점

본 연구에는 다음과 같은 한계가 있다.

- (1) 데이터 수가 약 181개로 제한적이다.
- (2) Apple Music preview는 길이가 짧아 장기적 음악 구조를 충분히 포함하지 않을 수 있다.
- (3) composer label이 metadata에서 직접 제공되지 않아 heuristic하게 추정되었다.
- (4) TDA feature는 full persistence diagram이 아니라 coarse graph-based proxy에 기반하였다.
- (5) TDA-only classifier는 DSP baseline보다 성능이 낮았다.
- (6) class imbalance로 인해 accuracy와 Macro F1 사이의 차이가 크게 나타났다.

이러한 한계는 향후 연구에서 개선해야 할 지점이다.

15 향후 연구

향후 연구는 다음 방향으로 확장할 수 있다.

15.1 Full Persistent Homology

현재는 coarse topological summary를 사용했지만, 향후에는 Ripser, GUDHI, Dionysus, JavaPlex 등의 library를 활용하여 정식 persistence diagram과 barcode를 계산할 수 있다.

15.2 Persistence Landscape 또는 Persistence Image

Persistence diagram은 직접 machine learning feature로 쓰기 어렵다. 따라서 persistence landscape 또는 persistence image로 변환하면 classifier나 neural network의 입력으로 사용할 수 있다.

15.3 Hybrid DSP+TDA Model

TDA-only model은 낮은 성능을 보였으므로, 향후에는 DSP feature와 TDA feature를 결합하는 방식이 적절하다.

$$f_{hybrid} = [f_{DSP}, f_{TDA}]. \quad (16)$$

이 hybrid feature를 사용하면, DSP의 local acoustic information과 TDA의 global structural information을 동시에 활용할 수 있다.

15.4 Deep Feature Space에 대한 TDA

Raw DSP feature가 아니라 CNN, autoencoder, contrastive learning model 등에서 나온 latent representation에 TDA를 적용할 수 있다. 이는 pointcloud_pca2가 상대적으로 좋은 결과를 보인 것과 연결된다. 즉, TDA는 raw coordinate보다 잘 정리된 latent acoustic space에서 더 효과적일 수 있다.

15.5 Longer Audio와 Musical Form

짧은 preview audio 대신 full-length audio를 사용하면, 반복, 변주, 회귀, section transition과 같은 더 긴 음악 구조를 분석할 수 있다. TDA는 이러한 global structure 분석에 더 적합할 가능성이 높다.

16 결론

본 연구는 MIR에서 DSP 기반 feature extraction과 TDA 기반 구조 분석을 결합하려는 시도이다. Apple Music string quartet preview audio를 대상으로 composer classification을 수행하였고, DSP baseline과 TDA baseline을 비교하였다.

DSP baseline은 높은 accuracy를 보였지만 Macro F1은 낮았으며, 이는 class imbalance와 minor class 분류의 어려움을 보여준다. TDA-only prototype은 classification 성능이 낮았지만, 음악 feature space의 구조를 분석하는 독립적인 관점을 제공하였다.

따라서 본 연구의 결론은 다음과 같다.

현재 단계에서 TDA는 DSP를 대체하기보다는, DSP feature space의 global structure를 보완하는 도구로 사용하는 것이 적절하다.

향후 full persistent homology, persistence landscape, hybrid DSP+TDA feature, deep latent feature space 분석으로 확장한다면, TDA는 MIR에서 음악적 구조와 유사도를 설명하는 강력한 도구가 될 수 있다.

References

- Alcalá-Alvarez, A., & Padilla-Longoria, P. *A Framework for Topological Music Analysis (TMA)*.
- Liu, J.-Y., Jeng, S.-K., & Yang, Y.-H. *Applying Topological Persistence in Convolutional Neural Network for Music Audio Signals*.
- Tran, M. L., Park, C., & Jung, J.-H. *Topological Data Analysis of Korean Music in Jeongganbo: A Cycle Structure*.
- Tran, M. L., Lee, D., & Jung, J.-H. *Machine Composition of Korean Music via Topological Data Analysis and Artificial Neural Network*.
- Son, W. *MIR with DSP and TDA*. S-Curt Research Report.