

S-Curt: MIR 연구 정리

Music Information Retrieval 기반 힙합 서브장르 분류

프로젝트명: S-Curt: MIR

연구 주제: Music Information Retrieval 기반 힙합 서브장르 분류

연구 기간: 2025.04.08 – 2025.07.07

핵심 키워드: Apple Music API, Preview Audio, Audio Feature Extraction, Soft K-Means, Neural Network, PCA

Contents

1	연구 배경	3
2	연구 목적	3
3	연구 대상 및 데이터 구성	3
3.1	대상 서브장르	3
3.2	수집 데이터	4
4	연구 흐름	4
5	오디오 피쳐 추출	4
5.1	주요 피쳐	4
5.2	피쳐 선정의 의미	5
6	모델 설계	5
6.1	Soft K-Means	5
6.2	Neural Network	5
7	연구 결과	6
7.1	데이터 요약	6
7.2	모델 성능	6
7.3	결과 해석	6
8	한계 및 개선 방안	7
8.1	비공식적 오디오 데이터의 한계	7
8.2	데이터 불균형	7

8.3 API 호출 제약	7
9 연구 의의	7
10 향후 연구 방향	8
11 결론	8
12 참고 문헌	9

1. 연구 배경

현대 음악 스트리밍 시장에서 사용자 취향에 맞춘 추천 시스템은 서비스 경쟁력의 핵심 요소이다. 특히 힙합 장르는 하나의 큰 장르로 묶이지만, 실제로는 Boom Bap, Trap, Rage, Ratchet, G-Funk 등 서로 다른 리듬, 템포, 사운드 디자인을 가지는 세부 서브장르들이 공존한다.

그러나 많은 음악 플랫폼에서는 이러한 세부 장르의 차이를 충분히 반영하지 못하고, “힙합”이라는 광역 태그 중심으로 음악을 분류하는 경우가 많다. 이로 인해 사용자의 실제 취향과 맞지 않는 추천이 발생할 수 있으며, 세부적인 음악적 흐름을 반영한 추천 시스템 설계가 어려워진다.

따라서 본 연구에서는 API를 통해 수집한 메타데이터와 미리듣기 오디오 데이터를 활용하여 힙합 서브장르를 분류하고, 어떤 오디오 피처가 장르 구분에 영향을 주는지 분석하고자 하였다.

2. 연구 목적

본 연구의 목적은 다음과 같다.

- Apple Music API를 활용하여 힙합 서브장르별 메타데이터와 Preview URL을 수집한다.
- Preview 오디오 파일에서 BPM, 에너지, 음색, 주파수 관련 피처를 추출한다.
- Soft K-Means와 Neural Network를 적용하여 서브장르 분류 가능성을 확인한다.
- 분류 성능과 혼동 행렬을 분석하여 오분류 원인과 한계를 파악한다.
- 향후 개인화 음악 추천 시스템으로 확장할 수 있는 방향성을 제시한다.

핵심 연구 질문

- API에서 제공하는 메타데이터와 Preview 오디오만으로 힙합 서브장르를 어느 정도 분류할 수 있는가?
- 추출한 오디오 피처 중 어떤 특성이 서브장르 간 차이를 만드는 데 중요한 역할을 하는가?

3. 연구 대상 및 데이터 구성

3.1. 대상 서브장르

본 연구에서는 힙합의 하위 장르 중 다음 다섯 가지를 대상으로 하였다.

1. Boom Bap
2. Trap
3. Rage
4. Ratchet
5. G-Funk

이 장르들은 모두 힙합이라는 큰 범주에 포함되지만, 리듬 패턴, 템포, 베이스 구조, 하이햇 사용 방식, 사운드 질감에서 차이를 가진다.

3.2. 수집 데이터

수집한 데이터는 크게 세 종류로 나눌 수 있다.

Table 1: 수집 데이터 구성

데이터 종류	내용
메타데이터	트랙명, 아티스트, 앨범명, 발매일, 재생 길이, Preview URL 등
Preview 오디오 오디오 피쳐	Apple Music에서 제공하는 미리듣기 m4a 파일 tempo, rms energy, zcr, MFCC, Chroma, spectral feature 등

최종적으로 약 4,132개의 Preview 오디오 파일을 수집하였고, 이를 바탕으로 오디오 피쳐를 추출하여 모델 학습에 사용하였다.

4. 연구 흐름

본 연구의 전체 흐름은 다음과 같다.

1. Apple Music API 토큰 생성
2. 장르별 트랙 검색 및 메타데이터 수집
3. Preview URL 추출
4. m4a Preview 파일 다운로드
5. 오디오 피쳐 추출
6. Soft K-Means를 통한 비지도 학습 실험
7. Neural Network를 통한 지도 학습 분류
8. 성능 평가 및 한계 분석

연구 진행 중 주요 전환점

초기에는 Apple Music과 Spotify API를 함께 활용하려 했으나, 두 API 모두 공식적인 오디오 분석 데이터를 충분히 제공하지 않는 문제가 있었다. 따라서 Apple Music의 Preview 파일을 직접 다운로드하고, 해당 오디오에서 피쳐를 추출하는 방식으로 연구 방향을 수정하였다.

5. 오디오 피쳐 추출

5.1. 주요 피쳐

Preview 오디오 파일에서 추출한 주요 피쳐는 다음과 같다.

Table 2: 주요 오디오 피쳐

Feature	의미
duration	트랙의 전체 재생 길이
tempo	분당 박자 수, 즉 BPM
rms_energy	신호의 평균 에너지로, 전체적인 음량감과 관련됨
zcr	Zero Crossing Rate. 파형이 0을 교차하는 비율
spectral_centroid	스펙트럼의 무게중심으로, 소리의 밝기와 관련됨
spectral_bandwidth	에너지가 분포하는 주파수 범위의 폭
spectral_contrast	저대역과 고대역의 에너지 대비
mfcc_mean	음색 정보를 나타내는 MFCC 계수의 평균
mfcc_d1_mean	시간에 따른 음색 변화량
low_freq_ratio	전체 에너지 중 저주파 성분의 비율
hh_clap_ratio	하이햇과 클랩의 상대적 비율
chroma_mean	화성적 특징을 나타내는 Chroma 성분

5.2. 피쳐 선정의 의미

힙합 서브장르는 단순히 멜로디보다 리듬, 저음, 드럼 패턴, 음색의 차이가 중요하다. 따라서 본 연구에서는 BPM과 같은 리듬 정보뿐 아니라, 저주파 비율, 하이햇과 클랩의 비율, MFCC, Chroma 등 다양한 피쳐를 함께 사용하였다.

특히 Trap, Rage, Ratchet 계열은 하이햇과 드럼 패턴이 중요하고, Boom Bap과 G-Funk는 샘플 질감, 저음 구조, 템포감에서 차이가 나타날 수 있기 때문에 여러 피쳐를 조합하는 방식이 필요했다.

6. 모델 설계

6.1. Soft K-Means

초기에는 비지도 학습 방법인 Soft K-Means를 사용하였다. Soft K-Means는 각 데이터가 하나의 클러스터에만 속하는 것이 아니라, 여러 클러스터에 확률적으로 속할 수 있도록 하는 방식이다.

음악 장르는 명확하게 나뉘기보다는 서로 겹치는 경우가 많기 때문에, 처음에는 Soft K-Means가 적합할 수 있다고 판단하였다.

그러나 실제 실험에서는 다음과 같은 문제가 있었다.

- 초기 중심값에 따라 결과가 크게 달라짐
- 장르 간 경계가 모호하여 클러스터가 명확히 형성되지 않음
- 실제 장르 라벨과 클러스터 결과가 잘 대응되지 않음

따라서 이후에는 지도 학습 방식인 Neural Network로 연구 방향을 전환하였다.

6.2. Neural Network

Neural Network는 추출한 오디오 피쳐를 입력으로 받아 각 트랙이 다섯 개의 힙합 서브장르 중 어디에 속하는지 분류하도록 설계하였다.

- 입력: 오디오 피쳐 및 일부 메타데이터
- 출력: Boom Bap, Trap, Rage, Ratchet, G-Funk 중 하나의 클래스
- 평가 지표: Accuracy, Precision, Recall, F1-score, Confusion Matrix

초기 성능은 약 20% 수준으로 낮았으나, 필요한 피쳐를 선별하고 데이터 수를 늘리면서 성능이 향상되었다.

7. 연구 결과

7.1. 데이터 요약

Table 3: 최종 데이터 요약

항목	값
전체 트랙 수	4,132곡
Feature 수	15개
메타데이터 Feature	2개
오디오 Feature	13개
분류 대상 장르	5개

7.2. 모델 성능

최종 Neural Network 모델의 성능은 다음과 같다.

Table 4: Neural Network 분류 성능

평가 지표	결과
Accuracy	49.3%
Precision	49.4%
Recall	46.7%
F1-score	46.7%

초기 약 20% 수준이었던 정확도는 데이터 수를 늘리고, 필요한 Feature를 선택하는 과정을 통해 최종적으로 49.3%까지 향상되었다. 이는 Preview 오디오라는 제한된 데이터만을 사용했다는 점을 고려하면 의미 있는 결과라고 볼 수 있다.

7.3. 결과 해석

분류 성능은 완벽하지 않았지만, 단순히 무작위로 다섯 장르를 분류하는 수준보다는 높은 성능을 보였다. 이는 Preview 오디오에서도 장르별 특징이 어느 정도 추출될 수 있음을 보여준다.

다만 정확도가 50% 전후에 머문 이유는 다음과 같이 해석할 수 있다.

- 힙합 서브장르 간 음악적 특징이 서로 겹치는 경우가 많음

- Preview는 전체 곡이 아니라 일부 구간만 제공되기 때문에 대표성이 부족함
- Ratchet, G-Funk 등 일부 장르의 데이터 수가 상대적으로 부족함
- Feature 수가 많다고 해서 항상 성능이 좋아지는 것은 아니었음

8. 한계 및 개선 방안

8.1. 비공식적 오디오 데이터의 한계

Apple Music과 Spotify API는 공식적인 오디오 분석 데이터를 충분히 제공하지 않는다. 따라서 본 연구에서는 Preview 파일을 직접 활용하여 오디오 피처를 추출하였다.

하지만 Preview는 곡 전체가 아니라 일부 구간만 제공되므로, 해당 구간이 곡 전체의 특징을 대표하지 못할 가능성이 있다. 향후 전체 음원 또는 공식 오디오 분석 데이터에 접근할 수 있다면 분류 성능을 더 높일 수 있을 것이다.

8.2. 데이터 불균형

Boom Bap, Trap, Rage와 같은 장르는 비교적 많은 데이터를 확보할 수 있었지만, Ratchet, G-Funk는 상대적으로 데이터가 부족했다. 이러한 데이터 불균형은 모델이 특정 장르에 편향되도록 만들 수 있다.

향후에는 다음과 같은 방법을 고려할 수 있다.

- 장르별 데이터 수를 균형 있게 맞추기
- 부족한 장르의 검색 키워드 확장
- 데이터 증강 기법 적용
- 클래스 가중치 조정

8.3. API 호출 제약

Apple Music API는 한 번에 반환하는 데이터 수가 제한되어 있어, 대규모 데이터를 빠르게 수집하기 어렵다. 또한 여러 연도와 장르를 조합하여 검색해야 하므로 코드 실행 시간이 길어지는 문제가 있었다.

향후에는 API 호출 구조를 최적화하고, 중복 데이터를 제거하는 전처리 과정을 강화할 필요가 있다.

9. 연구 의의

본 연구의 의의는 다음과 같다.

1. 실제 음악 플랫폼 API를 활용하여 데이터를 직접 수집하였다.
2. Preview 오디오에서 직접 오디오 피처를 추출하는 파이프라인을 구축하였다.

3. Soft K-Means, Neural Network, PCA 등 다양한 분석 방법을 실험하였다.
4. 힙합 서브장르 분류를 통해 음악 추천 시스템으로 확장할 가능성을 확인하였다.
5. 관심 분야인 음악과 전공 분야인 응용수학 및 데이터 분석을 연결하였다.

특히 단순히 주어진 데이터를 분석한 것이 아니라, 라이선스 획득, API 호출, Preview 다운로드, 오디오 피쳐 추출, 모델 학습까지 전체 파이프라인을 직접 구성했다는 점에서 의미가 있다.

10. 향후 연구 방향

본 연구는 S-Curt 프로그램 안에서 진행된 초기 MIR 프로젝트였으며, 향후 다음과 같은 방향으로 확장할 수 있다.

- 더 많은 장르와 아티스트로 데이터 확장
- 장르 분류가 아닌 아티스트 스타일 분석으로 확장
- Neural Network 구조 개선
- TDA를 활용한 음악 데이터의 위상적 구조 분석
- 개인화 추천 시스템 설계
- Swift 또는 iOS 앱과 연동한 음악 추천 서비스 구현

확장 아이디어

본 연구의 결과를 바탕으로 특정 힙합 아티스트가 어떤 서브장르적 특징을 많이 가지는지 분석할 수 있다. 예를 들어 한 아티스트의 곡들을 분류 모델에 입력하여, Boom Bap, Trap, Rage, Ratchet, G-Funk 중 어느 스타일에 가까운 곡이 많은지 확인할 수 있다. 이는 향후 아티스트 기반 추천 시스템이나 음악 스타일 지도 제작으로 확장될 수 있다.

11. 결론

본 연구에서는 Apple Music API와 Preview 오디오를 활용하여 힙합 서브장르 분류를 위한 MIR 기반 분석 파이프라인을 구축하였다. 초기에는 Soft K-Means를 활용한 비지도 학습을 시도했으나, 장르 간 경계가 모호하고 클러스터링 성능이 낮아 Neural Network 기반 지도 학습으로 전환하였다.

최종적으로 약 4,132개의 Preview 오디오 데이터를 수집하고, 15개의 Feature를 활용하여 다섯 개 힙합 서브장르 분류를 수행하였다. 모델의 최종 정확도는 49.3%로 나타났으며, 이는 제한된 Preview 오디오만을 활용했다는 점에서 의미 있는 결과이다.

다만 Preview 데이터의 한계, 장르별 데이터 불균형, API 호출 제약 등으로 인해 분류 성능에는 한계가 있었다. 향후에는 데이터 균형을 개선하고, 더 정교한 피쳐 선정과 모델 구조 개선을 통해 성능을 향상시킬 수 있을 것이다.

이 연구는 음악 추천 시스템, 장르 분류, 아티스트 스타일 분석 등으로 확장될 수 있으며, 응용수학과 음악 데이터 분석을 연결하는 초기 연구로서 의미를 가진다.

12. 참고 문헌

- 니키타 브라긴스키, *수학이 사랑한 음악*
- 윤보국, 「감성 기반 음악 검색 및 추천 시스템 설계」, 2011.
- Apple Music API Documentation.
- MATLAB Audio Toolbox Documentation.