

Identifying A Human Emotion

딥러닝 기반 인간 감정 이미지 분류 프로젝트

본 프로젝트는 48×48 크기의 흑백 얼굴 이미지를 입력으로 받아 인간의 감정을 분류하는 딥러닝 모델을 구현하고 비교하는 것을 목표로 한다. 기본적인 완전 연결 신경망인 FCNN과 이미지의 공간적 구조를 활용하는 CNN을 비교하였으며, 최종적으로 데이터 증강을 적용한 CNN이 더 높은 성능을 보였다.

Contents

1 프로젝트 개요	3
1.1 문제 정의	3
1.2 프로젝트 목적	3
2 데이터셋	3
2.1 데이터 출처	3
2.2 무작위 기준 성능	4
3 데이터 전처리	4
3.1 데이터 정제	4
3.2 정규화	4
3.3 데이터 균형	4
4 모델 1: FCNN	5
4.1 FCNN 구조	5
4.2 모델 구성	5
4.3 FCNN의 장점과 한계	5
5 모델 2: CNN	6
5.1 CNN을 사용한 이유	6
5.2 CNN 구조	6
5.3 CNN의 장점과 한계	6
6 FCNN과 CNN의 성능 비교	7
6.1 정확도 비교	7
6.2 해석	7

7 문제점과 해결 방법	7
7.1 문제점: 높은 Loss	7
7.2 해결 방법: Data Augmentation	7
7.3 Data Augmentation의 효과	8
8 최종 결과	8
9 개선점	8
9.1 더 크고 좋은 데이터셋 사용	8
9.2 다양한 Data Augmentation 전략	9
9.3 Pre-trained Model 사용	9
10 결론	9

1 프로젝트 개요

본 프로젝트의 주제는 **Identifying A Human Emotion**이다. 즉, 사람의 얼굴 이미지가 주어졌을 때 해당 얼굴이 어떤 감정을 나타내는지 분류하는 문제를 다룬다.

1.1 문제 정의

입력 데이터는 48×48 픽셀 크기의 흑백 얼굴 이미지이며, 모델은 다음 다섯 가지 감정 중 하나를 예측해야 한다.

Angry	Happy	Sad	Fear	Surprise
-------	-------	-----	------	----------

수학적으로는 입력 이미지 $X \in \mathbb{R}^{48 \times 48}$ 가 주어졌을 때, 감정 클래스 y 를 예측하는 분류 함수 f 를 학습하는 문제로 볼 수 있다.

$$f(X) = y, \quad y \in \{\text{Angry, Happy, Sad, Fear, Surprise}\}$$

1.2 프로젝트 목적

이 프로젝트의 목적은 단순히 감정을 맞히는 모델을 만드는 것뿐만 아니라, 딥러닝 모델 구조에 따라 이미지 분류 성능이 어떻게 달라지는지 확인하는 것이다.

특히 다음 두 모델을 비교하였다.

- FCNN: 이미지를 하나의 긴 벡터로 펼쳐서 분류하는 기본 모델
- CNN: 이미지의 공간적 구조를 고려하여 특징을 추출하는 모델

최종적으로는 CNN이 FCNN보다 이미지 분류 문제에 더 적합하다는 것을 확인하는 것이 핵심이다.

2 데이터셋

2.1 데이터 출처

본 프로젝트에서는 Kaggle의 **human-face-emotions** 데이터셋을 사용하였다. 데이터는 사람 얼굴 이미지로 구성되어 있으며, 각 이미지는 특정 감정 클래스로 라벨링되어 있다.

항목	내용
데이터 출처	Kaggle human-face-emotions dataset
이미지 크기	48×48 pixels
이미지 형태	Grayscale image
클래스 수	5 classes
감정 종류	Angry, Happy, Sad, Fear, Surprise
전체 이미지 수	39,915 images

2.2 무작위 기준 성능

감정 클래스가 총 5개이므로, 아무 학습 없이 무작위로 하나의 클래스를 선택할 경우 정답을 맞힐 확률은 다음과 같다.

$$P(\text{correct}) = \frac{1}{5} = 0.2$$

따라서 기본적으로 넘어야 하는 baseline accuracy는 다음과 같다.

$$\text{Baseline Accuracy} = 20\%$$

즉, 모델이 의미 있는 학습을 했다고 말하기 위해서는 최소한 20%보다 높은 정확도를 보여야 한다.

3 데이터 전처리

3.1 데이터 정제

실제 이미지 데이터에는 모델 학습에 방해가 되는 샘플들이 포함될 수 있다. 따라서 다음과 같은 데이터 정제 과정을 수행하였다.

- 48×48 크기가 아닌 이미지 제거
- 흑백 이미지가 아닌 데이터 제거
- 얼굴이 제대로 보이지 않는 이미지 제거
- 완전히 검정색이거나 흐릿한 이미지 제거
- 노이즈가 심한 샘플 수동 제거

이 과정은 모델이 실제 얼굴의 감정 특징을 학습하도록 돕기 위한 단계이다.

3.2 정규화

원본 흑백 이미지는 픽셀 값이 0부터 255 사이의 정수로 표현된다. 딥러닝 모델은 일반적으로 입력 값의 범위가 너무 크면 학습이 불안정해질 수 있으므로, 픽셀 값을 0과 1 사이로 정규화하였다.

$$x_{\text{normalized}} = \frac{x}{255}$$

즉, 기존 픽셀 값의 범위는 다음과 같이 변환된다.

$$0 \leq x \leq 255 \implies 0 \leq x_{\text{normalized}} \leq 1$$

3.3 데이터 균형

감정 데이터셋은 각 클래스의 이미지 개수가 완전히 동일하지 않을 수 있다. 특정 감정 클래스의 데이터가 지나치게 많으면 모델이 해당 클래스에 편향될 수 있다.

따라서 학습 과정에서는 클래스 간 데이터 불균형을 완화하는 것이 중요하다. 이는 모델이 특정 감정만 잘 맞히는 것이 아니라, 다섯 가지 감정을 전반적으로 구분할 수 있도록 하기 위함이다.

4 모델 1: FCNN

4.1 FCNN 구조

첫 번째 모델은 **Fully Connected Neural Network, FCNN**이다. FCNN은 이미지를 2차원 구조로 보지 않고, 하나의 긴 벡터로 펼친 뒤 Dense layer를 통과시키는 방식이다.

48×48 이미지는 다음과 같이 2304차원 벡터로 변환된다.

$$48 \times 48 = 2304$$

따라서 입력층은 2304개의 노드를 가진다.

4.2 모델 구성

발표 자료에서 사용한 FCNN 구조는 다음과 같다.

단계	Layer	설명
1	Flatten	48×48 이미지를 2304차원 벡터로 변환
2	Dense 1024	ReLU 활성화 함수 사용
3	Dense 512	ReLU 활성화 함수 사용
4	Dense 256	ReLU 활성화 함수 사용
5	Dense 128	ReLU 활성화 함수 사용
6	Dense 5	Softmax 출력층

출력층의 5개 노드는 각각 다음 감정 클래스에 대한 확률을 의미한다.

$$\hat{y} = \begin{bmatrix} P(\text{Angry}) \\ P(\text{Happy}) \\ P(\text{Sad}) \\ P(\text{Fear}) \\ P(\text{Surprise}) \end{bmatrix}$$

4.3 FCNN의 장점과 한계

FCNN의 가장 큰 장점은 구현이 간단하다는 것이다. 이미지를 벡터로 변환한 뒤 기본적인 Dense layer만 사용하면 되기 때문에 구조를 이해하기 쉽다.

그러나 FCNN은 이미지의 공간적 구조를 무시한다는 한계가 있다. 예를 들어 얼굴 이미지에서 눈, 입, 눈썹의 위치 관계는 감정을 구분하는 데 매우 중요하다. 하지만 FCNN은 이미지를 단순히 긴 숫자 배열로 보기 때문에 이러한 위치 정보를 충분히 활용하기 어렵다.

FCNN의 핵심 한계는 이미지의 공간적 정보를 잃는다는 점이다. 즉, 얼굴의 특정 부위가 어디에 위치하는지, 주변 픽셀과 어떤 관계를 가지는지를 제대로 반영하지 못한다.

발표 자료 기준 FCNN의 전체 파라미터 수는 다음과 같다.

$$\text{Total Parameters}_{\text{FCNN}} = 3,049,989$$

5 모델 2: CNN

5.1 CNN을 사용한 이유

두 번째 모델은 **Convolutional Neural Network, CNN**이다. CNN은 이미지 분류 문제에서 널리 사용되는 구조이며, 이미지의 공간적 특징을 효과적으로 추출할 수 있다.

CNN은 단순히 픽셀 값을 나열하는 것이 아니라, 작은 필터를 이용해 이미지의 지역적 패턴을 탐지한다. 예를 들어 다음과 같은 특징을 학습할 수 있다.

- 눈과 눈썹의 방향
- 입꼬리의 위치
- 얼굴의 윤곽
- 표정 변화에 따른 국소적 패턴

5.2 CNN 구조

발표 자료에서 사용한 CNN 구조는 다음과 같다.

단계	Layer	설명
1	Input	48×48 흑백 이미지 입력
2	Conv2D 32, 3×3	32개의 합성곱 필터 사용
3	MaxPooling	공간 크기 축소 및 주요 특징 유지
4	Conv2D 64, 3×3	더 복잡한 특징 추출
5	MaxPooling	특징 맵 크기 축소
6	Conv2D 128, 3×3	고수준 얼굴 특징 추출
7	MaxPooling	특징 압축
8	Flatten	특징 맵을 벡터로 변환
9	Dense Softmax	5개 감정 클래스 확률 출력

5.3 CNN의 장점과 한계

CNN의 장점은 이미지의 지역적 특징과 공간적 구조를 활용할 수 있다는 점이다. 따라서 얼굴 표정처럼 위치와 형태가 중요한 이미지 분류 문제에서 FCNN보다 더 적합하다.

반면 CNN은 FCNN보다 구조가 복잡하며, 충분한 데이터와 연산량이 필요하다는 단점이 있다. 하지만 본 프로젝트에서는 CNN이 FCNN보다 훨씬 적은 파라미터를 사용하면서도 더 높은 성능을 보였다.

발표 자료 기준 CNN의 전체 파라미터 수는 다음과 같다.

$$\text{Total Parameters}_{\text{CNN}} = 102,917$$

이는 FCNN의 파라미터 수보다 훨씬 적다. 즉, CNN은 더 적은 파라미터로도 이미지의 중요한 특징을 효과적으로 학습할 수 있었다.

6 FCNN과 CNN의 성능 비교

6.1 정확도 비교

테스트 데이터, 즉 학습에 사용되지 않은 unseen data에 대해 두 모델의 성능을 비교하였다.

모델	테스트 정확도	특징
FCNN	약 60%	구현은 간단하지만 이미지 구조 반영 부족
CNN	약 75%	공간적 특징을 활용하여 더 높은 성능 달성

무작위 기준 성능이 20%였다는 점을 고려하면 두 모델 모두 의미 있는 학습을 수행하였다. 그러나 CNN은 FCNN보다 약 15%p 높은 정확도를 보였다.

$$75\% - 60\% = 15\%$$

6.2 해석

FCNN은 모든 픽셀을 독립적인 입력값처럼 다루기 때문에 이미지 내부의 구조적 정보를 충분히 활용하지 못한다. 반면 CNN은 합성곱 필터를 통해 눈, 입, 얼굴 윤곽과 같은 지역적 특징을 추출할 수 있다.

따라서 본 프로젝트의 결과는 다음과 같이 정리할 수 있다.

얼굴 감정 분류와 같은 이미지 분류 문제에서는 단순 FCNN보다 CNN이 더 적합하다. CNN은 이미지의 공간적 구조를 활용할 수 있기 때문에 더 높은 정확도를 얻을 수 있다.

7 문제점과 해결 방법

7.1 문제점: 높은 Loss

CNN은 높은 정확도를 보였지만, 학습 과정에서 loss가 여전히 크게 나타나는 문제가 있었다. 이는 모델이 훈련 데이터에 지나치게 맞춰지는 overfitting 가능성을 의미한다.

정확도는 높더라도 validation loss가 크다면, 모델이 새로운 데이터에 대해 안정적으로 일반화하지 못할 수 있다.

7.2 해결 방법: Data Augmentation

이 문제를 완화하기 위해 **Data Augmentation**을 적용하였다. Data Augmentation은 기존 이미지를 변형하여 새로운 학습 샘플처럼 사용하는 방법이다.

본 프로젝트에서는 다음과 같은 augmentation layer를 사용하였다.

기법	설명
RandomFlip("horizontal")	이미지를 좌우 반전
RandomRotation(0.2)	이미지를 일정 범위 내에서 회전
RandomZoom(0.2)	이미지를 확대 또는 축소

7.3 Data Augmentation의 효과

Data Augmentation을 사용하면 실제 데이터 수를 직접 늘리지 않더라도, 모델은 더 다양한 형태의 얼굴 이미지를 학습하게 된다.

이를 통해 다음과 같은 효과를 기대할 수 있다.

- 데이터셋의 다양성 증가
- 작은 위치 변화나 회전에 대한 강건성 향상
- overfitting 감소
- validation loss 안정화

즉, augmentation은 모델이 단순히 학습 데이터의 특정 형태를 외우는 것이 아니라, 다양한 얼굴 변형에도 감정을 인식할 수 있도록 돕는다.

8 최종 결과

최종적으로 본 프로젝트에서는 다음과 같은 결론을 얻었다.

1. 감정 분류 문제의 무작위 기준 성능은 20%이다.
2. FCNN은 약 60%의 테스트 정확도를 보였다.
3. CNN은 약 75%의 테스트 정확도를 보였다.
4. CNN은 FCNN보다 이미지의 공간적 특징을 더 잘 활용하였다.
5. Data Augmentation은 overfitting을 줄이고 일반화 성능을 높이는 데 도움을 주었다.

본 프로젝트의 핵심 결론은 다음과 같다.

CNN with Data Augmentation > Basic FCNN

즉, 48×48 흑백 얼굴 이미지 기반 감정 분류에서는 데이터 증강을 적용한 CNN이 기본 FCNN보다 더 좋은 성능을 보였다.

9 개선점

본 프로젝트는 기본적인 얼굴 감정 분류 모델을 구현하고 비교했다는 점에서 의미가 있지만, 더 발전시킬 수 있는 부분도 존재한다.

9.1 더 크고 좋은 데이터셋 사용

현재 데이터셋은 48×48 흑백 이미지로 구성되어 있다. 이미지 해상도가 낮기 때문에 얼굴의 세밀한 표정 변화를 충분히 반영하기 어렵다.

더 큰 이미지, 더 다양한 인종, 나이, 조명, 얼굴 각도를 포함한 데이터셋을 사용하면 모델의 성능을 더 높일 수 있다.

9.2 다양한 Data Augmentation 전략

본 프로젝트에서는 좌우 반전, 회전, 확대 및 축소를 사용하였다. 추가적으로 다음과 같은 augmentation도 고려할 수 있다.

- 밝기 변화
- 대비 조절
- 랜덤 이동
- 랜덤 크롭
- 노이즈 추가

이를 통해 모델이 실제 환경에서 발생하는 다양한 이미지 변화에 더 잘 대응할 수 있다.

9.3 Pre-trained Model 사용

더 높은 성능을 위해 사전 학습된 모델을 사용할 수도 있다. 예를 들어 ImageNet과 같은 대규모 이미지 데이터셋에서 학습된 모델을 활용하면, 적은 데이터로도 더 좋은 성능을 얻을 가능성이 있다.

다만 본 프로젝트의 입력 이미지는 48×48 흑백 이미지이므로, pre-trained model을 사용하기 위해서는 입력 크기와 채널 수를 맞추는 추가 전처리가 필요하다.

10 결론

본 프로젝트는 얼굴 이미지 기반 감정 분류 문제를 통해 FCNN과 CNN의 차이를 비교하였다. FCNN은 구현이 간단하지만 이미지의 공간적 구조를 무시한다는 한계가 있었다. 반면 CNN은 합성곱 연산을 통해 얼굴의 지역적 특징을 추출할 수 있었고, 그 결과 더 높은 정확도를 보였다.

또한 CNN에 Data Augmentation을 적용함으로써 overfitting 문제를 완화하고 모델의 일반화 성능을 개선할 수 있었다.

따라서 본 프로젝트는 딥러닝에서 모델 구조 선택이 성능에 큰 영향을 미친다는 점을 보여준다. 특히 이미지 분류 문제에서는 데이터의 구조를 고려할 수 있는 CNN이 기본적인 FCNN보다 더 적합하다는 것을 확인할 수 있었다.