

IPIU 2026: Diffusion Models

Diffusion 모델의 Exponential Integrator에 대한 다항식 근사 기반 해석

Abstract

본 연구는 Diffusion 모델의 샘플링 과정을 Probability Flow ODE 관점의 시간적분 문제로 해석한다. 기본적인 DDPM 기반 샘플링은 안정적이지만 많은 step을 요구하며, step 수를 줄이면 샘플 품질이 급격히 저하될 수 있다. 이에 본 연구에서는 Euler, Heun, DPM-Solver, UniPC 계열 샘플러를 Exponential Integrator와 다항식 근사 관점에서 비교한다. 특히 샘플러의 차수가 높아질수록 적은 step에서도 적분 오차가 줄어들고, 이미지의 구조와 디테일이 더 안정적으로 보존된다는 점을 설명한다. 실험적으로도 Euler 기반 저스텝 샘플링보다 Heun 및 DPM-Solver 기반 샘플링이 더 안정적인 복원 결과를 보임을 확인하였다.

1 연구 배경

Diffusion 모델은 데이터에 점진적으로 Gaussian noise를 추가하는 forward process와, noise로부터 데이터를 복원하는 reverse process를 통해 샘플을 생성하는 생성 모델이다. DDPM은 이러한 구조를 확률적 Markov chain으로 정식화하여 고품질 이미지 생성을 가능하게 했다.

그러나 DDPM의 기본 샘플링 방식은 일반적으로 수백에서 수천 번의 denoising step을 요구한다. 이는 계산 비용이 크고, 실제 응용에서 생성 속도를 제한하는 문제가 된다. 따라서 최근 Diffusion 모델 연구에서는 적은 step으로도 높은 품질의 샘플을 생성할 수 있는 빠른 sampler가 중요한 주제가 되었다.

본 연구의 핵심 관점은 다음과 같다.

Diffusion sampler의 성능 차이는 단순한 알고리즘 차이가 아니라, Probability Flow ODE의 적분항을 어떤 차수로 근사하느냐의 차이로 해석할 수 있다.

2 문제 정의

Diffusion 샘플링은 noise 상태에서 시작하여 점진적으로 clean data를 복원하는 과정이다. 일반적으로 초기 상태는 다음과 같이 주어진다.

$$x_T \sim \mathcal{N}(0, I). \quad (1)$$

샘플러는 x_T 에서 출발하여 역방향으로 x_0 를 생성한다. 문제는 sampling step 수를 줄였을 때 발생한다. step 수가 줄어들면 각 step의 간격이 커지고, numerical integration error가 커진다. 그 결과 이미지 구조가 붕괴되거나 디테일이 손실될 수 있다.

따라서 본 연구의 연구 질문은 다음과 같다.

RQ. Diffusion sampler의 차수가 저스텝 샘플링 품질을 결정하는 핵심 요인인가?

이에 대한 가설은 다음과 같다.

Hypothesis. 샘플러의 근사 차수가 높을수록 누적 적분 오차가 감소하고, 적은 step에서도 이미지의 구조와 디테일이 더 안정적으로 유지될 것이다.

3 Diffusion Forward Process

깨끗한 데이터 $x_0 \sim p_{\text{data}}$ 에 대해, 시간 t 에서의 noisy sample x_t 는 다음과 같이 표현된다.

$$x_t = \alpha_t x_0 + \sigma_t z, \quad z \sim \mathcal{N}(0, I). \quad (2)$$

여기서 α_t 는 signal schedule, σ_t 는 noise schedule이다. Variance-preserving 계열에서는 보통 다음 조건을 사용한다.

$$\alpha_t^2 + \sigma_t^2 = 1. \quad (3)$$

DDPM의 이산 표기에서는 다음과 같이 쓰기도 한다.

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (4)$$

이는 clean data에 시간에 따라 noise를 점진적으로 섞는 과정이다. t 가 커질수록 signal 성분은 줄어들고 noise 성분은 커진다.

4 모델 출력 Parameterization

Diffusion 모델은 보통 다음 세 가지 중 하나를 예측한다.

- (1) noise prediction: $\epsilon_\theta(x_t, t) \approx \epsilon$
- (2) data prediction: $x_\theta(x_t, t) \approx x_0$
- (3) velocity prediction: $v_\theta(x_t, t) \approx v$

본 연구에서는 설명을 단순화하기 위해 data prediction 모델을 중심으로 둔다. 즉, 신경망은 다음을 예측한다고 가정한다.

$$x_\theta(x_t, t) \approx x_0. \quad (5)$$

noise prediction과 data prediction은 서로 변환 가능하다. 만약 noise prediction 모델을 사용한다면 clean data 추정치는 다음과 같다.

$$\hat{x}_0 = \frac{x_t - \sigma_t \epsilon_\theta(x_t, t)}{\alpha_t}. \quad (6)$$

반대로 data prediction 모델이 주어졌을 때 noise 추정치는 다음과 같다.

$$\hat{\epsilon} = \frac{x_t - \alpha_t x_\theta(x_t, t)}{\sigma_t}. \quad (7)$$

따라서 sampler의 수학적 해석에서는 어떤 parameterization을 쓰더라도 서로 변환하여 비교할 수 있다.

5 Probability Flow ODE

Diffusion model의 reverse process는 확률적 SDE로 볼 수도 있지만, 동일한 marginal distribution을 갖는 결정론적 ODE로도 표현할 수 있다. 이를 Probability Flow ODE라고 한다.

Data prediction 모델 x_θ 에 대해 Probability Flow ODE는 다음과 같이 쓸 수 있다.

$$\frac{dx_t}{dt} = \left(f(t) + \frac{g^2(t)}{2\sigma_t^2} \right) x_t - \frac{\alpha_t g^2(t)}{2\sigma_t^2} x_\theta(x_t, t). \quad (8)$$

여기서 계수 함수는 diffusion schedule로부터 정의된다.

$$f(t) = \frac{d \log \alpha_t}{dt}, \quad (9)$$

$$g^2(t) = \frac{d\sigma_t^2}{dt} - 2 \frac{d \log \alpha_t}{dt} \sigma_t^2. \quad (10)$$

이 관점에서 diffusion sampling은 단순한 denoising 반복이 아니라, ODE를 역방향으로 수치적분하는 문제로 볼 수 있다.

6 Log-SNR 변수와 적분 해

Diffusion ODE를 효율적으로 해석하기 위해 log-SNR 변수를 도입한다.

$$\lambda(t) = \log \left(\frac{\alpha_t^2}{\sigma_t^2} \right) = 2 \log \alpha_t - 2 \log \sigma_t. \quad (11)$$

시간 변수 t 를 λ 로 재파라미터화하면, Probability Flow ODE의 해는 다음과 같은 적분 형태로 표현된다.

$$x_t = \frac{\sigma_t}{\sigma_s} x_s + \sigma_t \int_{\lambda_s}^{\lambda_t} e^\lambda x_\theta(x_\lambda, \lambda) d\lambda. \quad (12)$$

따라서 핵심은 다음 적분항을 어떻게 근사하느냐이다.

$$\int_{\lambda_s}^{\lambda_t} e^\lambda x_\theta(x_\lambda, \lambda) d\lambda. \quad (13)$$

Euler, Heun, DPM-Solver, UniPC는 모두 이 적분항을 서로 다른 방식과 차수로 근사하는 방법으로 해석할 수 있다.

7 Euler Sampler: 1차 근사

Euler 방법은 현재 시점의 변화율만을 사용하여 다음 상태를 예측하는 1차 적분법이다. 적분항을 좌단값으로 근사하면 다음과 같다.

$$\int_{\lambda_s}^{\lambda_t} e^{\lambda} x_{\theta}(x_{\lambda}, \lambda) d\lambda \approx (\lambda_t - \lambda_s) e^{\lambda_s} x_{\theta}(x_s, \lambda_s). \quad (14)$$

이를 이용하면 다음 상태는 다음과 같이 계산된다.

$$x_t \approx \frac{\sigma_t}{\sigma_s} x_s + \sigma_t (\lambda_t - \lambda_s) e^{\lambda_s} x_{\theta}(x_s, \lambda_s). \quad (15)$$

Euler 방법은 구현이 매우 단순하지만, step 간격이 커질수록 local truncation error가 커진다. 따라서 적은 step으로 샘플링할 때 구조 붕괴나 디테일 손실이 쉽게 발생한다.

8 Heun Sampler: 2차 Predictor–Corrector

Heun 방법은 Euler 방법의 예측값을 만든 뒤, 시작점과 예측점의 변화율을 평균내어 보정하는 2차 Predictor–Corrector 방식이다.

먼저 Euler predictor를 계산한다.

$$\tilde{x}_t = \frac{\sigma_t}{\sigma_s} x_s + \sigma_t (\lambda_t - \lambda_s) e^{\lambda_s} x_{\theta}(x_s, \lambda_s). \quad (16)$$

그 다음 corrector 단계에서 적분항을 사다리꼴 규칙으로 근사한다.

$$\int_{\lambda_s}^{\lambda_t} e^{\lambda} x_{\theta}(x_{\lambda}, \lambda) d\lambda \approx \frac{\lambda_t - \lambda_s}{2} \left(e^{\lambda_s} x_{\theta}(x_s, \lambda_s) + e^{\lambda_t} x_{\theta}(\tilde{x}_t, \lambda_t) \right). \quad (17)$$

Heun 방법은 Euler 방법보다 계산량은 조금 증가하지만, 동일한 step 수에서 더 작은 적분 오차를 갖는다. 따라서 저스텝 샘플링에서 더 안정적인 결과를 기대할 수 있다.

9 DPM-Solver: 고차 Exponential Integrator

DPM-Solver는 diffusion sampling을 Probability Flow ODE의 고차 수치적분 문제로 해석한다. 핵심은 적분항의 integrand를 λ 에 대한 다항식으로 근사하는 것이다.

$$x_{\theta}(x_{\lambda}, \lambda) \approx \sum_{k=0}^{p-1} a_k (\lambda - \lambda_s)^k. \quad (18)$$

이를 적분식에 대입하면, 지수항 e^λ 가 포함된 적분을 닫힌 형태로 계산할 수 있다. 이때 등장하는 함수가 exponential integrator에서 사용하는 ϕ -function이다.

대표적으로 다음과 같은 함수들이 사용된다.

$$\phi_1(h) = \frac{e^h - 1}{h}, \quad (19)$$

$$\phi_2(h) = \frac{e^h - h - 1}{h^2}, \quad (20)$$

$$\phi_3(h) = \frac{e^h - \frac{h^2}{2} - h - 1}{h^3}. \quad (21)$$

DPM-Solver의 1차 형태는 다음과 같이 표현할 수 있다.

$$x_t = \frac{\alpha_t}{\alpha_s} x_s - \sigma_t (e^h - 1) \epsilon_\theta(x_s, s). \quad (22)$$

여기서 $h = \lambda_t - \lambda_s$ 이다. 고차 DPM-Solver는 이전 또는 중간 시점의 model evaluation을 활용하여 ϵ_θ 의 변화까지 반영한다.

DPM-Solver의 장점은 큰 step size에서도 높은 정확도를 유지할 수 있다는 점이다. 따라서 10–20 step 정도의 매우 적은 sampling step에서도 좋은 품질을 기대할 수 있다.

10 UniPC: Unified Predictor–Corrector Framework

UniPC는 다양한 diffusion sampler를 하나의 Predictor–Corrector framework 안에서 통합적으로 해석한다. DPM-Solver가 exponential integrator 기반의 특정 고차 solver라면, UniPC는 predictor와 corrector를 결합하여 더 일반적인 고차 sampler를 구성한다.

UniPC의 핵심은 model output을 보조 시점들의 Lagrange interpolation으로 근사하는 것이다. 보조 시점 λ_{s_m} 에서의 model evaluation을 사용하여 다음과 같이 근사한다.

$$\hat{\epsilon}_\theta(\hat{x}_\lambda, \lambda) \approx \sum_{m=0}^n l_m(\lambda) \hat{\epsilon}_\theta(\hat{x}_{\lambda_{s_m}}, \lambda_{s_m}). \quad (23)$$

이를 적분식에 대입하면 다음과 같이 쓸 수 있다.

$$x_t = \frac{\alpha_t}{\alpha_s} x_s - \sigma_t \sum_{m=0}^n h a_m \hat{\epsilon}_\theta(\hat{x}_{\lambda_{s_m}}, \lambda_{s_m}). \quad (24)$$

계수 a_m 은 Lagrange interpolation과 exponential integral에 의해 결정된다. 따라서 UniPC는 DDIM과 같은 1차 sampler부터 DPM-Solver 계열의 고차 sampler까지 포함할 수 있는 통합적 구조를 제공한다.

Table 1: Diffusion sampling algorithm 비교

Method	Viewpoint	Type	Typical Steps	Main Idea
DDPM	Reverse SDE	Stochastic	~ 1000	Markov Gaussian denoising
DDIM	Probability Flow ODE	Deterministic	$50 \sim 100$	Deterministic path with same marginals
Euler	1st-order ODE solver	Deterministic	Few-many	Current slope only
Heun	2nd-order PC solver	Deterministic	Few-many	Average of predicted slopes
DPM-Solver	High-order exponential ODE solver	Deterministic	$10 \sim 20$	Polynomial approximation with closed-form exponential integral
UniPC	Unified PC framework	Deterministic	$10 \sim 20$	Unified high-order predictor-corrector

11 샘플러 비교

수치해석 관점에서 sampler의 발전 흐름은 다음과 같이 요약할 수 있다.

$$\text{DDPM} \rightarrow \text{DDIM} \rightarrow \text{DPM-Solver} \rightarrow \text{UniPC}. \quad (25)$$

또는 수치적분 관점에서는 다음과 같이 정리할 수 있다.

$$\text{Euler} \rightarrow \text{Heun} \rightarrow \text{DPM-Solver} \rightarrow \text{UniPC}. \quad (26)$$

이는 단순히 알고리즘이 복잡해지는 과정이 아니라, Probability Flow ODE의 적분항을 더 높은 차수로 정확하게 근사하는 방향으로 발전한 것으로 볼 수 있다.

12 실험 결과 해석

본 연구의 포스터 실험에서는 동일한 이미지 생성 조건에서 Euler 기반 샘플링과 Heun, DPM-Solver 기반 샘플링을 비교하였다. 특히 step 수를 5 step으로 크게 줄였을 때, Euler 방식은 이미지의 구조와 디테일이 쉽게 흐려지는 반면, Heun과 DPM-Solver는 상대적으로 더 안정적인 구조를 유지하였다.

이는 다음과 같이 해석할 수 있다.

- (1) Euler는 1차 근사이므로 큰 step에서 오차가 크게 누적된다.
- (2) Heun은 예측점의 변화율을 추가로 사용하여 2차 정확도를 갖는다.
- (3) DPM-Solver는 지수 가중 적분항을 고차 다항식으로 근사하므로 저스텝에서도 안정적이다.

따라서 실험 결과는 본 연구의 가설, 즉 “샘플러의 근사 차수가 높을수록 적은 step에서도 품질이 안정적으로 유지된다”는 설명과 일치한다.

13 연구의 의의

본 연구의 의의는 다음과 같다.

- (1) Diffusion sampler를 확률적 생성 과정이 아니라 ODE 수치적분 문제로 재해석하였다.
- (2) Euler, Heun, DPM-Solver, UniPC를 하나의 근사 차수 관점에서 비교하였다.
- (3) 고급 sampler의 성능 향상을 “적분 오차 감소”라는 수학적 언어로 설명하였다.
- (4) 저스텝 diffusion sampling에서 발생하는 품질 저하를 수치해석적으로 이해할 수 있는 관점을 제시하였다.

특히 본 연구는 단순히 새로운 모델을 제안하기보다는, 이미 존재하는 sampler들의 원리를 수학적으로 정리하고 비교하는 데 초점을 둔다. 이는 Diffusion 모델을 공부하는 학생이나 연구자가 sampler 구조를 직관적으로 이해하는 데 도움을 줄 수 있다.

14 한계점 및 향후 연구

본 연구에는 몇 가지 한계가 있다.

첫째, 실험이 제한된 모델과 이미지 예시에 기반하고 있어, 다양한 dataset과 model architecture에서의 정량적 검증이 추가로 필요하다.

둘째, Euler, Heun, DPM-Solver의 비교는 수행하였지만, UniPC에 대한 직접적인 실험 비교는 충분히 포함되지 않았다. 향후 연구에서는 UniPC까지 포함하여 step 수별 FID, CLIP score, reconstruction error 등을 비교할 수 있다.

셋째, 본 연구는 sampler의 차수와 품질 사이의 관계를 중심으로 설명하지만, 실제 생성 품질에는 noise schedule, guidance scale, model architecture, prompt 조건 등 다양한 요소가 함께 영향을 준다.

향후에는 다음과 같은 방향으로 확장할 수 있다.

- (1) Euler, Heun, DPM-Solver, UniPC의 step 수별 정량 비교
- (2) latent trajectory의 안정성 분석
- (3) local truncation error와 image quality metric 사이의 관계 분석
- (4) text-to-image diffusion model에서 guidance scale과 solver order의 상호작용 분석

15 결론

본 연구는 Diffusion 모델의 샘플링 과정을 Probability Flow ODE의 시간적분 문제로 해석하였다. 기본 Euler sampler는 구현이 단순하지만, 적은 step에서는 적분 오차가 크게 누적되어 이미지 품질이 저하될 수 있다. 반면 Heun, DPM-Solver, UniPC와 같은 고차 sampler는 적분항을 더 정확하게 근사함으로써 저스텝 샘플링에서도 구조와 디테일을 안정적으로 유지할 수 있다.

결론적으로 Diffusion sampler의 발전은 더 빠른 생성을 위한 단순한 engineering improvement가 아니라, **Probability Flow ODE의 적분 정확도를 높이는 수치해석적 발전**으로 이해할 수 있다.

References

1. J. Ho, A. Jain, and P. Abbeel, “Denoising Diffusion Probabilistic Models,” *Advances in Neural Information Processing Systems*, 2020.
2. J. Song, C. Meng, and S. Ermon, “Denoising Diffusion Implicit Models,” *International Conference on Learning Representations*, 2021.
3. Y. Song and S. Ermon, “Generative Modeling by Estimating Gradients of the Data Distribution,” *Advances in Neural Information Processing Systems*, 2019.
4. C. Lu, Y. Zhou, F. Bao, J. Chen, C. Li, and J. Zhu, “DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling in Around 10 Steps,” *Advances in Neural Information Processing Systems*, 2022.
5. W. Zhao, L. Bai, Y. Rao, J. Zhou, and J. Lu, “UniPC: A Unified Predictor-Corrector Framework for Fast Sampling of Diffusion Models,” *Advances in Neural Information Processing Systems*, 2023.
6. M. Hochbruck and A. Ostermann, “Exponential Integrators,” *Acta Numerica*, vol. 19, pp. 209–286, 2010.