

KWMS 2026 연구 정리

Directional Kernel Approximation을 활용한 단일 흉부 X-ray Bone Suppression 연구

Abstract

흉부 X-ray 영상은 폐 질환 진단에 널리 사용되지만, 갈비뼈와 쇄골 등의 뼈 구조가 폐 영역 위에 겹쳐 나타나기 때문에 작은 결절이나 병변의 관찰을 방해할 수 있다. 기존의 dual-energy subtraction 방식은 뼈와 연조직을 분리할 수 있지만 특수 장비가 필요하다는 한계가 있으며, 딥러닝 기반 bone suppression 방법은 충분한 학습 데이터가 필요하다. 본 연구는 단일 흉부 X-ray 영상만을 사용하여, 영상의 gradient와 방향성을 분석하고 directional kernel approximation을 적용함으로써 rib-like structure를 추정하고 이를 억제하는 비딥러닝 기반 bone suppression 알고리즘을 설계하는 것을 목표로 한다.

1 연구 배경

Chest X-ray, 즉 CXR은 흉부 X-ray 영상을 의미하며, 폐, 심장, 갈비뼈, 쇄골, 횡격막 등의 구조를 2차원 영상으로 나타낸다. 그러나 CXR은 3차원 인체 구조를 2차원 평면에 투영한 영상이기 때문에, 폐 영역 위에 갈비뼈와 쇄골 같은 뼈 구조가 겹쳐 나타난다.

이러한 뼈 구조는 결핵 병변, 폐 결절, 폐렴 음영과 같은 미세한 이상 소견을 가릴 수 있다. 따라서 CXR 영상에서 뼈 구조의 영향을 줄이는 것은 폐 병변을 더 잘 보이게 만드는 데 중요한 의미가 있다.

Bone suppression의 목적은 CXR 영상에서 갈비뼈와 쇄골의 시각적 영향을 줄여 soft-tissue visibility를 향상시키는 것이다. 즉, 단순히 영상을 보기 좋게 만드는 것이 아니라, 폐 내부의 병변과 연조직 구조가 더 명확하게 관찰되도록 만드는 전처리 과정이다.

2 문제 정의

일반적인 흉부 X-ray 영상에서는 다음과 같은 문제가 발생한다.

- 갈비뼈와 쇄골이 폐 영역 위에 겹쳐 나타난다.
- 뼈 구조의 강한 edge가 폐 내부의 미세한 병변을 가릴 수 있다.
- 단일 X-ray 영상만으로는 뼈 성분과 연조직 성분이 명확히 분리되어 있지 않다.
- 딥러닝 기반 방법은 ground truth soft-tissue image 또는 DES image가 필요할 수 있다.

따라서 본 연구의 핵심 문제는 다음과 같이 정리할 수 있다.

단일 흉부 X-ray 영상만을 입력으로 사용하여, 뼈 구조의 방향성과 gradient 정보를 기반으로 rib-like component를 추정하고 이를 억제할 수 있는가?

이를 수식적으로 표현하면 원본 흉부 X-ray 영상을 I 라고 할 때, bone component B_{bone} 를 추정하고, 최종적으로 bone-suppressed image I_{soft} 를 생성하는 문제로 볼 수 있다.

$$I \longrightarrow B_{\text{bone}} \longrightarrow I_{\text{soft}}$$

최종 목표는 다음과 같은 형태의 영상을 얻는 것이다.

$$I_{\text{soft}} = I - \alpha B_{\text{bone}},$$

여기서 α 는 bone suppression strength를 조절하는 파라미터이다.

3 기존 연구

3.1 Dual-Energy Subtraction

Dual-energy subtraction, 즉 DES 방식은 서로 다른 에너지 수준에서 X-ray를 촬영한 뒤, 두 영상을 조합하여 뼈 성분과 연조직 성분을 분리하는 방법이다. 이 방법은 soft-tissue image를 직접 생성할 수 있다는 장점이 있다.

하지만 DES 방식은 다음과 같은 한계를 가진다.

- 특수한 X-ray 촬영 장비가 필요하다.
- 두 번의 노출 과정에서 환자의 움직임이 발생하면 motion artifact가 생길 수 있다.
- 모든 병원 환경에서 쉽게 사용할 수 있는 방법은 아니다.

따라서 단일 CXR만을 이용한 software-only bone suppression 방법이 필요하다.

3.2 CamsNet 기반 Bone Suppression

Yang et al.은 단일 CXR에서 bone suppression을 수행하기 위해 gradient domain에서 bone image를 예측하는 CamsNet 구조를 제안하였다. 이 방법은 CXR의 intensity 자체가 아니라 gradient를 입력으로 사용하여, 원본 CXR의 gradient와 bone image의 gradient 사이의 mapping을 학습한다.

핵심 아이디어는 다음과 같다.

- CXR의 gradient는 bone component와 soft-tissue component를 intensity domain보다 더 잘 분리할 수 있다.
- 여러 scale에서 ConvNet을 cascade 구조로 연결하여 bone gradient를 점진적으로 예측한다.

- 예측된 bone gradient를 통합하여 bone image를 추정한다.
- 추정된 bone image를 원본 CXR에서 빼서 soft-tissue image를 생성한다.

이를 간단히 표현하면 다음과 같다.

$$(I_x, I_y) \longrightarrow (B_x, B_y) \longrightarrow B_{\text{bone}} \longrightarrow I_{\text{soft}}.$$

여기서 I_x, I_y 는 원본 CXR의 gradient이고, B_x, B_y 는 bone image의 gradient이다.

본 연구는 CamsNet의 “gradient domain에서 뼈 구조를 추정한다”는 관점은 참고하되, 딥러닝 학습을 직접 수행하기보다는 수학적 gradient approximation과 directional kernel을 이용한 비딥러닝 baseline을 구성한다.

3.3 Anisotropic Diffusion과 Directional Filtering

Anisotropic diffusion은 영상의 모든 방향을 동일하게 smoothing하는 isotropic diffusion과 달리, 구조의 방향에 따라 smoothing 강도를 다르게 조절하는 방법이다. 일반적인 anisotropic diffusion 방정식은 다음과 같다.

$$\frac{\partial u}{\partial t} = \nabla \cdot (D \nabla u),$$

여기서 u 는 diffusion이 진행되는 영상이고, D 는 diffusion tensor이다.

D 는 영상의 local structure에 따라 방향별 smoothing 정도를 조절한다. 예를 들어 edge를 가로지르는 방향으로는 diffusion을 약하게 하고, edge를 따라가는 방향으로는 diffusion을 강하게 할 수 있다. 이를 통해 noise는 줄이면서도 중요한 구조는 보존할 수 있다.

본 연구에서는 이러한 방향성 기반 영상처리의 관점을 활용하여, 갈비뼈와 쇄골처럼 길고 방향성을 가진 구조를 추정하고 억제하는 방향으로 접근한다.

4 제안 방법

4.1 전체 파이프라인

본 연구의 전체 흐름은 다음과 같다.

$$I \longrightarrow \nabla I \longrightarrow \text{Directional Kernel Approximation} \longrightarrow B_{\text{bone}} \longrightarrow I_{\text{soft}}.$$

보다 구체적으로는 다음 단계로 구성된다.

1. 입력 흉부 X-ray 영상을 grayscale image로 불러온다.
2. intensity normalization을 수행한다.

3. Sobel filter 또는 directional derivative를 이용하여 gradient를 계산한다.
4. local region에서 방향성을 추정한다.
5. directional kernel approximation을 통해 rib-like response를 계산한다.
6. 여러 방향과 여러 scale의 response를 통합하여 bone candidate map을 만든다.
7. bone candidate map을 원본 영상에서 attenuation하여 bone-suppressed image를 생성한다.
8. 필요시 CLAHE 등의 contrast enhancement를 적용하여 soft-tissue visibility를 높인다.

5 수학적 구성

5.1 Input Normalization

원본 X-ray 영상을 I_{raw} 라고 하자. 먼저 pixel intensity를 $[0, 1]$ 범위로 정규화한다.

$$I(x, y) = \frac{I_{\text{raw}}(x, y) - I_{\min}}{I_{\max} - I_{\min} + \epsilon}.$$

여기서 $I_{\min}$ 과 $I_{\max}$ 는 각각 영상의 최소 및 최대 intensity이고, ϵ 은 분모가 0이 되는 것을 방지하기 위한 작은 양수이다.

5.2 Image Gradient

정규화된 영상을 $I(x, y)$ 라고 하면, gradient는 다음과 같다.

$$\nabla I(x, y) = (I_x(x, y), I_y(x, y)) = \left(\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y} \right).$$

Gradient magnitude는 다음과 같이 정의된다.

$$\|\nabla I(x, y)\| = \sqrt{I_x(x, y)^2 + I_y(x, y)^2}.$$

CXR에서 gradient magnitude가 큰 영역은 갈비뼈 경계, 쇄골 경계, 폐 경계, 병변 경계 등일 수 있다. 따라서 gradient만으로는 bone structure를 완전히 분리할 수 없고, 방향성 정보가 함께 필요하다.

5.3 Structure Tensor

Local orientation을 추정하기 위해 structure tensor를 사용할 수 있다. 먼저 Gaussian smoothing된 영상 u_σ 의 gradient를 계산하고, gradient의 outer product를 다시 Gaussian kernel K_ρ 로 smoothing 한다.

$$J_\rho = K_\rho * (\nabla u_\sigma \nabla u_\sigma^T).$$

2차원 영상에서는 다음과 같이 쓸 수 있다.

$$J_\rho = K_\rho * \begin{pmatrix} u_x^2 & u_x u_y \\ u_x u_y & u_y^2 \end{pmatrix}.$$

Structure tensor의 eigenvalue와 eigenvector를 계산하면,

$$J_\rho v_i = \mu_i v_i, \quad i = 1, 2.$$

여기서 μ_i 는 eigenvalue이고, v_i 는 해당 eigenvector이다. 일반적으로 두 eigenvalue의 차이가 크면 해당 local region은 강한 방향성을 가진다.

5.4 Coherency Measure

Local directionality의 강도를 나타내기 위해 coherency measure를 다음과 같이 정의할 수 있다.

$$C(x, y) = \left(\frac{\mu_1 - \mu_2}{\mu_1 + \mu_2 + \epsilon} \right)^2.$$

여기서 $\mu_1 \geq \mu_2$ 라고 하자.

$$C(x, y) \approx 1 \quad \Rightarrow \quad \text{강한 방향성 구조},$$

$$C(x, y) \approx 0 \quad \Rightarrow \quad \text{방향성이 약한 영역}.$$

갈비뼈와 쇠골은 길고 얇은 곡선형 구조이기 때문에, 특정 local region에서 높은 coherency를 보일 수 있다.

5.5 Directional Kernel Approximation

본 연구의 핵심은 local data의 방향성을 고려하는 kernel을 이용해 gradient 또는 rib-like structure를 근사하는 것이다.

방향 θ 를 갖는 directional kernel을 K_θ 라고 하면, 해당 방향에 대한 response는 다음과 같이 정의할 수 있다.

$$R_\theta(x, y) = |K_\theta * I|(x, y).$$

여러 방향에 대해 response를 계산한 뒤, 가장 큰 값을 선택한다.

$$R(x, y) = \max_{\theta \in \Theta} R_\theta(x, y).$$

여기서 Θ 는 후보 방향들의 집합이다. 예를 들어,

$$\Theta = \{0^\circ, 15^\circ, 30^\circ, \dots, 165^\circ\}$$

와 같이 둘 수 있다.

5.6 Multi-Scale Rib Candidate Map

갈비뼈와 쇠골은 위치와 개인에 따라 두께와 곡률이 다르기 때문에, 하나의 kernel size만 사용하는 것은 충분하지 않다. 따라서 여러 scale의 directional response를 결합한다.

scale l 에 대한 response를 $R_l(x, y)$ 라고 하면,

$$R_l(x, y) = \max_{\theta \in \Theta} |K_{l,\theta} * I|(x, y).$$

여러 scale을 결합하면 raw bone candidate map은 다음과 같다.

$$B_{\text{raw}}(x, y) = \sum_{l=1}^L w_l R_l(x, y),$$

여기서 w_l 은 각 scale에 대한 가중치이며,

$$\sum_{l=1}^L w_l = 1$$

로 둘 수 있다.

5.7 Spatial Weighting

CXR 영상에서 rib-like response는 폐 영역뿐 아니라 body outline, 어깨, 쇠골 주변에서도 강하게 나타날 수 있다. 따라서 폐 영역 중심부를 더 신뢰하기 위한 spatial weighting을 적용할 수 있다.

간단한 타원형 weight function을 다음과 같이 정의한다.

$$W(x, y) = \exp \left(- \left(\frac{x - x_c}{a} \right)^2 - \left(\frac{y - y_c}{b} \right)^2 \right),$$

여기서 (x_c, y_c) 는 영상 중심, a, b 는 각각 가로 및 세로 방향 scale parameter이다.

이를 bone candidate map에 곱한다.

$$B_{\text{weighted}}(x, y) = W(x, y) B_{\text{raw}}(x, y).$$

5.8 Bone Map Normalization

Bone candidate map의 값 범위를 안정적으로 맞추기 위해 percentile normalization을 적용한다.

$$v_{\text{low}} = \text{percentile}(B_{\text{weighted}}, p_{\text{low}}),$$

$$v_{\text{high}} = \text{percentile}(B_{\text{weighted}}, p_{\text{high}}).$$

정규화된 bone map은 다음과 같다.

$$B(x, y) = \text{clip}\left(\frac{B_{\text{weighted}}(x, y) - v_{\text{low}}}{v_{\text{high}} - v_{\text{low}} + \epsilon}, 0, 1\right).$$

5.9 Bone Suppression

최종적으로 bone map을 이용해 원본 영상에서 rib-like structure를 약화한다.

$$I_{\text{bs}}(x, y) = I(x, y) (1 - \alpha B(x, y)).$$

여기서 α 는 suppression strength이다.

$$0 \leq \alpha \leq 1.$$

α 가 클수록 뼈 구조는 더 강하게 억제되지만, 동시에 연조직 정보도 손실될 수 있다. 따라서 α 는 실험적으로 조절해야 한다.

5.10 Soft-Tissue Enhancement

Bone suppression 이후 soft-tissue visibility를 높이기 위해 CLAHE와 같은 local contrast enhancement를 추가할 수 있다. CLAHE 결과를 $C_{\text{clahe}}(x, y)$ 라고 하면, 최종 soft-tissue image는 다음과 같이 정의할 수 있다.

$$I_{\text{soft}}(x, y) = I_{\text{bs}}(x, y) + \beta W(x, y) (C_{\text{clahe}}(x, y) - I_{\text{bs}}(x, y)).$$

여기서 β 는 contrast enhancement strength이다.

6 알고리즘 요약

본 연구에서 제안하는 classical bone suppression baseline은 다음과 같이 정리할 수 있다.

1. 원본 CXR 영상 I_{raw} 를 입력한다.

2. intensity normalization을 통해 $I \in [0, 1]$ 로 변환한다.
3. 여러 방향과 여러 scale의 directional kernel response를 계산한다.
4. 각 위치에서 최대 방향 response를 선택한다.
5. multi-scale response를 결합하여 B_{raw} 를 만든다.
6. spatial weighting을 적용하여 폐 영역 중심부의 response를 강조한다.
7. percentile normalization을 통해 bone map B 를 생성한다.
8. $I_{\text{bs}} = I(1 - \alpha B)$ 를 계산하여 rib-like structure를 억제한다.
9. CLAHE 기반 local contrast enhancement를 적용하여 최종 I_{soft} 를 생성한다.

7 기존 방법과 제안 방법 비교

Table 1: 기존 Bone Suppression 방법과 제안 방법의 비교

구분	기존 방법	제안 방법
입력 영상	DES 또는 학습용 CXR dataset	단일 흉부 X-ray 영상
핵심 원리	뼈 영상 또는 연조직 영상을 학습 기반으로 예측	gradient와 방향성 기반 rib-like structure 추정
알고리즘 유형	딥러닝 또는 proprietary software	비딥러닝 classical image processing
필요 데이터	다량의 paired data 또는 DES image 필요	단일 영상만 사용 가능
장점	높은 품질의 bone-suppressed image 생성 가능	해석 가능성이 높고 데이터 의존도가 낮음
한계	학습 데이터와 모델이 필요함	true bone-only map을 정확히 분리하기 어려움

8 실험 및 구현 방향

실험에서는 다음과 같은 결과를 비교한다.

- 원본 CXR 영상
- gradient magnitude image
- directional response map
- estimated bone map
- bone-suppressed image

- contrast-enhanced soft-tissue image

정량 평가가 가능한 경우 다음 지표를 사용할 수 있다.

- PSNR
- SSIM
- gradient energy reduction
- rib-like response suppression ratio

다만 ground truth soft-tissue image가 없는 경우, PSNR이나 SSIM은 제한적으로만 사용할 수 있다. 이 경우에는 시각적 비교와 rib-like response 감소율을 중심으로 평가한다.

9 현재 한계

현재 방법의 가장 큰 한계는 estimated bone map이 true bone-only map이 아니라는 점이다. 즉,

$$B(x, y) \neq B_{\text{true bone}}(x, y).$$

현재의 $B(x, y)$ 는 갈비뼈와 쇄골뿐 아니라 body outline, 폐 경계, 강한 혈관 구조, 영상 상단의 강한 선 구조에도 반응할 수 있다. 따라서 최종 결과는 “완전한 bone-free soft-tissue image”라기보다는 “rib-like line structure가 attenuation된 image”에 가깝다.

또한 단일 CXR만으로는 뼈 뒤에 가려진 연조직 정보를 완전히 복원할 수 없다. Bone suppression은 뼈 구조를 제거한다기보다, 뼈 음영의 시각적 영향력을 줄이는 문제로 이해하는 것이 더 정확하다.

10 향후 연구 방향

향후 연구 방향은 다음과 같다.

1. Lung field segmentation 도입

폐 영역 외부의 false response를 줄이기 위해 lung mask를 적용한다.

2. Clavicle과 rib 구조 분리

쇄골은 갈비뼈와 방향 및 위치가 다르므로 별도의 directional prior를 적용할 수 있다.

3. Multi-scale directional kernel 개선

다양한 곡률을 가진 rib structure를 더 잘 잡기 위해 curved kernel 또는 steerable filter를 사용할 수 있다.

4. Anisotropic diffusion과 결합

Structure tensor 기반 coherency map을 이용하여 방향성이 강한 구조만 선택적으로 smoothing 또는 attenuation한다.

5. Deep learning method와 비교

CamsNet, ResNet-BS 등의 딥러닝 방법과 비교하여 classical baseline의 장단점을 분석한다.

11 결론

본 연구는 단일 흉부 X-ray 영상에서 갈비뼈와 쇄골의 영향을 줄이기 위한 비딥러닝 기반 bone suppression 방법을 다룬다. 기존의 DES 방식은 특수 장비가 필요하고, 딥러닝 기반 방식은 대량의 학습 데이터가 필요하다는 한계가 있다. 이에 본 연구에서는 gradient, local orientation, directional kernel approximation을 이용하여 rib-like structure를 추정하고 이를 원본 영상에서 attenuation 하는 classical baseline을 제안한다.

핵심 수식은 다음과 같이 요약할 수 있다.

$$R_l(x, y) = \max_{\theta \in \Theta} |K_{l, \theta} * I|(x, y),$$

$$B_{\text{raw}}(x, y) = \sum_{l=1}^L w_l R_l(x, y),$$

$$B(x, y) = \text{clip} \left(\frac{W(x, y) B_{\text{raw}}(x, y) - v_{\text{low}}}{v_{\text{high}} - v_{\text{low}} + \epsilon}, 0, 1 \right),$$

$$I_{\text{bs}}(x, y) = I(x, y) (1 - \alpha B(x, y)).$$

따라서 본 방법은 뼈를 완전히 제거하는 모델이라기보다, 단일 X-ray 영상에서 rib-like structures를 검출하고 약화시켜 soft-tissue visibility를 개선하려는 해석 가능한 classical baseline으로 볼 수 있다.

References

- [1] W. Yang, Y. Chen, Y. Liu, L. Zhong, G. Qin, Z. Lu, Q. Feng, and W. Chen, “Cascade of Multi-Scale Convolutional Neural Networks for Bone Suppression of Chest Radiographs in Gradient Domain,” *Medical Image Analysis*, vol. 35, pp. 421–433, 2017.
- [2] F. Li, R. Engelmann, L. L. Pesce, K. Doi, C. E. Metz, and H. MacMahon, “Small Lung Cancers: Improved Detection by Use of Bone Suppression Imaging—Comparison with Dual-Energy Subtraction Chest Radiography,” *Radiology*, vol. 261, no. 3, pp. 937–949, 2011.
- [3] J. Weickert, *Anisotropic Diffusion in Image Processing*, Teubner, Stuttgart, 1998.
- [4] J.-M. Mirebeau, J. Fehrenbach, L. Risser, and S. Tobji, “Anisotropic Diffusion in ITK,” arXiv:1503.00992, 2015.
- [5] Y. J. Lee and J. Yoon, “Nonlinear Image Upsampling Method Based on Radial Basis Function Interpolation,” *IEEE Transactions on Image Processing*, vol. 19, no. 10, pp. 2682–2692, 2010.