

MIR with DSP

S-Curt Research Project

Music Information Retrieval with Digital Signal Processing

90년대 힙합 장르 분류를 위한 DSP 기반 오디오 Feature 분석

2025학년도 2학기 S-Curt 연구 프로젝트

응용수리과학부

Contents

1	프로젝트 개요	3
2	연구 배경 및 필요성	3
3	연구 목적	3
4	데이터 구성	4
4.1	연구 대상 장르	4
4.1.1	Boombap	4
4.1.2	G-Funk	4
4.2	수집 데이터	4
5	DSP 분석: FFT와 STFT	5
5.1	FFT	5
5.2	STFT	5
6	오디오 Feature 추출	6
6.1	Spectral Centroid	6
6.2	Spectral Bandwidth	7
6.3	Spectral Flatness	7
6.4	Spectral Flux	7
6.5	Low-Frequency Energy Ratio	7
6.6	High-Frequency Energy Ratio	8
7	모델 설계 및 학습	8
7.1	Neural Network	8
7.2	Random Forest	8
8	연구 결과	9
9	한계점 및 개선 방안	9

9.1	기존 Feature 사용	9
9.2	데이터 불균형	9
9.3	모델 최적화 부족	10
10	연구 의의	10
11	향후 연구 방향	10
11.1	다른 힙합 서브장르로 확장	10
11.2	직접 Feature 설계	10
11.3	추천 시스템으로의 응용	11
11.4	TDA 기반 MIR로 확장	11
12	결론	11
	참고 문헌	12

1. 프로젝트 개요

본 프로젝트는 **MIR with DSP**를 주제로 진행한 S-Curt 연구이다. MIR은 Music Information Retrieval, 즉 음악 정보 검색을 의미하며, 음악으로부터 유용한 정보를 추출하여 장르 분류, 유사곡 추천, 플레이리스트 생성 등에 활용하는 분야이다.

이번 연구에서는 기존 MIR 연구에서 한 단계 더 나아가, 음악 추천 및 장르 분류에 사용되는 오디오 feature들이 실제로 어떤 **디지털 신호처리(Digital Signal Processing, DSP)** 과정을 통해 만들어지는지 분석하였다. 특히 FFT와 STFT를 기반으로 오디오 신호를 주파수 영역으로 변환하고, 이를 바탕으로 spectral feature를 추출하였다.

연구 대상은 90년대 힙합의 두 대표적인 서브장르인 **Boombap**과 **G-Funk**이다. Apple Music에서 수집한 미리듣기 오디오 데이터를 이용하여 각 곡의 오디오 feature를 추출하고, 이를 바탕으로 머신러닝 모델을 학습시켜 두 장르를 분류하였다.

핵심 요약

본 연구는 90년대 힙합 서브장르인 Boombap과 G-Funk를 대상으로, Apple Music 미리듣기 오디오에서 DSP 기반 feature를 추출하고, Neural Network와 Random Forest를 비교하여 장르 분류 성능을 분석한 프로젝트이다.

2. 연구 배경 및 필요성

음악 스트리밍 서비스에서는 사용자의 취향에 맞는 곡을 추천하거나, 곡의 장르를 자동으로 분류하는 기능이 중요하다. 이러한 기능의 기반에는 음악에서 특징을 추출하고 분석하는 MIR 기술이 존재한다.

하지만 MIR에서 사용되는 오디오 feature들은 단순한 숫자가 아니다. 이 feature들은 대부분 오디오 신호를 수학적으로 변환하는 DSP 과정을 통해 계산된다. 예를 들어, 특정 곡이 밝게 들리는지, 저음이 강한지, 드럼 변화가 많은지는 모두 주파수 영역의 정보를 통해 정량화할 수 있다.

따라서 본 연구에서는 단순히 머신러닝 모델을 적용하는 것에 그치지 않고, 다음 질문에 집중하였다.

- MIR에서 사용되는 feature들은 DSP를 어떻게 활용하는가?
- FFT와 STFT는 오디오 feature 계산에서 어떤 역할을 하는가?
- Boombap과 G-Funk의 청각적 차이를 수치적으로 표현할 수 있는가?
- Neural Network와 Random Forest 중 어떤 모델이 장르 분류에 더 적합한가?

3. 연구 목적

본 연구의 목적은 다음과 같다.

1. DSP 기반 오디오 feature 이해

FFT와 STFT를 통해 음악 신호가 어떻게 주파수 영역으로 변환되는지 이해하고, 이 변환 결과가 spectral feature 계산에 어떻게 사용되는지 분석한다.

2. 90년대 힙합 서브장르 분류

Boombap과 G-Funk를 대상으로 오디오 feature를 추출하고, 이를 이용해 두 장르를 분류하는 모델을 구현한다.

3. 머신러닝 모델 비교

Neural Network와 Random Forest를 비교하여, 제한된 데이터 환경에서 어떤 모델이 더 안정적인 성능을 보이는지 확인한다.

4. 향후 MIR 연구 확장 기반 마련

기존 feature를 이해하는 것을 넘어, 향후 직접 feature를 설계하거나 TDA 기반 MIR 연구로 확장할 수 있는 기초를 마련한다.

4. 데이터 구성

4.1. 연구 대상 장르

본 연구에서는 90년대 힙합의 대표적인 두 서브장르인 **Boombap**과 **G-Funk**를 연구 대상으로 설정하였다.

4.1.1. Boombap

Boombap은 주로 동부 힙합을 대표하는 스타일로, 강한 킥과 스네어, 타이트한 드럼 패턴, 샘플 기반의 거친 질감이 특징이다. 리듬이 명확하고 드럼이 전면에 드러나는 경우가 많다.

4.1.2. G-Funk

G-Funk는 주로 서부 힙합을 대표하는 스타일로, 부드러운 신디사이저, 여유로운 그루브, 공간감 있는 사운드가 특징이다. 전반적으로 Boombap보다 더 부드럽고 넓은 질감을 가진다.

4.2. 수집 데이터

Apple Music API와 미리듣기 URL을 활용하여 다음과 같은 데이터를 수집하였다.

Table 1: 수집 데이터 구성

구분	내용
메타데이터	트랙명, 아티스트, 앨범, 발매일, 재생 길이, 미리듣기 URL 등
오디오 데이터	Apple Music preview m4a 파일
대상 장르	Boombap, G-Funk
전체 트랙 수	약 1,264곡
Feature 수	8개

최종적으로 각 곡은 8개의 오디오 feature로 표현되며, 각 곡의 장르 라벨은 Boombap 또는 G-Funk로 설정하였다.

5. DSP 분석: FFT와 STFT

5.1. FFT

FFT는 Fast Fourier Transform의 약자로, 시간 영역의 신호를 주파수 영역으로 변환하는 알고리즘이다. 음악 신호는 시간에 따라 진폭이 변하는 파형으로 주어지지만, 이 파형만으로는 어떤 주파수 성분이 포함되어 있는지 직접 알기 어렵다.

FFT를 적용하면 하나의 오디오 신호 안에 어떤 주파수가 얼마나 포함되어 있는지 확인할 수 있다.

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N} \quad (1)$$

여기서 $x[n]$ 은 시간 영역의 오디오 신호이고, $X[k]$ 는 k 번째 주파수 성분의 크기와 위상을 나타낸다. FFT는 계산이 빠르고 구현이 간단하다는 장점이 있지만, 시간에 따라 주파수 성분이 어떻게 변하는지는 파악하기 어렵다.

5.2. STFT

STFT는 Short-Time Fourier Transform의 약자로, 신호를 짧은 구간으로 나눈 뒤 각 구간마다 FFT를 적용하는 방법이다. 음악은 시간에 따라 드럼, 보컬, 신디사이저, 베이스 등이 계속 변화하기 때문에, 전체 신호를 한 번에 분석하는 FFT만으로는 충분하지 않다.

STFT는 다음과 같이 표현할 수 있다.

$$X(k, m) = \sum_n x[n]w[n - mR]e^{-j2\pi kn/N} \quad (2)$$

여기서 $w[n - mR]$ 은 m 번째 프레임에 적용되는 window function이고, R 은 hop size를 의미한다. STFT를 사용하면 시간에 따른 주파수 성분의 변화를 확인할 수 있다.

FFT와 STFT의 차이

FFT는 곡 전체에 어떤 주파수 성분이 포함되어 있는지 확인하는 데 유용하고, STFT는 시간에 따라 주파수 성분이 어떻게 변하는지 확인하는 데 유용하다. 따라서 드럼, 리듬, 하이햇, 스네어처럼 시간적으로 변화하는 요소를 분석할 때 STFT가 더 적합하다.

6. 오디오 Feature 추출

본 연구에서는 FFT와 STFT로부터 계산되는 spectral feature들을 사용하였다. 각 곡은 다음 8개의 feature로 표현되었다.

Table 2: 사용한 오디오 Feature

Feature	의미
Mean Spectral Centroid	곡 전체의 평균 밝기
Std Spectral Centroid	밝기 변화 정도
Mean Spectral Bandwidth	주파수 에너지 분포 범위
Std Spectral Bandwidth	대역폭 변화 정도
Mean Spectral Flatness	스펙트럼의 평탄성
Mean Spectral Flux	프레임 간 스펙트럼 변화량
Mean Low-Frequency Energy Ratio	300Hz 이하 저역 에너지 비율
Mean High-Frequency Energy Ratio	4000Hz 이상 고역 에너지 비율

6.1. Spectral Centroid

Spectral Centroid는 스펙트럼의 무게중심을 의미한다. 쉽게 말하면 곡의 밝기를 나타내는 지표이다. 고주파 에너지가 많을수록 값이 커지며, 하이햇이나 신디사이저가 두드러지는 곡에서 높게 나타날 수 있다.

$$C(m) = \frac{\sum_k f_k X(k, m)}{\sum_k X(k, m)} \quad (3)$$

곡 전체의 평균 Spectral Centroid는 다음과 같이 계산한다.

$$\bar{C} = \frac{1}{M} \sum_{m=1}^M C(m) \quad (4)$$

6.2. Spectral Bandwidth

Spectral Bandwidth는 에너지가 주파수 영역에서 얼마나 넓게 퍼져 있는지를 나타낸다. 값이 클수록 다양한 주파수 대역에 에너지가 분포한다는 의미이다.

$$BW(m) = \sqrt{\sum_k (f_k - C(m))^2 p(k, m)} \quad (5)$$

여기서 $p(k, m)$ 은 각 주파수 성분의 정규화된 에너지 비율이다.

6.3. Spectral Flatness

Spectral Flatness는 스펙트럼이 얼마나 평탄한지를 나타낸다. 값이 1에 가까울수록 에너지가 여러 주파수 대역에 고르게 퍼져 있다는 의미이며, 값이 작을수록 특정 주파수에 에너지가 집중되어 있다는 의미이다.

$$SF(m) = \frac{\exp\left(\frac{1}{K} \sum_k \log(P(k, m) + \epsilon)\right)}{\frac{1}{K} \sum_k P(k, m)} \quad (6)$$

6.4. Spectral Flux

Spectral Flux는 프레임 사이에서 스펙트럼이 얼마나 많이 변하는지를 나타낸다. 드럼 히트나 리듬 변화가 많은 곡일수록 값이 커질 수 있다.

$$SFx(m) = \sum_{k \in K} (M(k, m) - M(k, m-1))^2 \quad (7)$$

곡 전체의 평균 Spectral Flux는 다음과 같이 계산한다.

$$\overline{SFx} = \frac{1}{M-1} \sum_{m=2}^M SFx(m) \quad (8)$$

6.5. Low-Frequency Energy Ratio

Low-Frequency Energy Ratio는 300Hz 이하의 저역대 에너지가 전체 에너지에서 차지하는 비율이다. 킁과 베이스가 강한 곡에서 높게 나타날 수 있다.

$$K_{low} = \{k : f_k \leq 300Hz\} \quad (9)$$

$$LFER(m) = \frac{\sum_{k \in K_{low}} P(k, m)}{\sum_{k \in K_{all}} P(k, m)} \quad (10)$$

6.6. High-Frequency Energy Ratio

High-Frequency Energy Ratio는 4000Hz 이상의 고역대 에너지가 전체 에너지에서 차지하는 비율이다. 하이햇, 스네어, 밝은 신디사이저가 두드러지는 곡에서 높게 나타날 수 있다.

$$K_{high} = \{k : f_k \geq 4000Hz\} \quad (11)$$

$$HFER(m) = \frac{\sum_{k \in K_{high}} P(k, m)}{\sum_{k \in K_{all}} P(k, m)} \quad (12)$$

7. 모델 설계 및 학습

본 연구에서는 추출된 8개의 feature를 입력으로 사용하여 Boombap과 G-Funk를 분류하는 모델을 학습시켰다. 비교한 모델은 **Neural Network**와 **Random Forest**이다.

7.1. Neural Network

Neural Network는 입력층, 은닉층, 출력층으로 구성된 모델이다. 입력층에는 8개의 오디오 feature가 들어가며, 은닉층에서는 비선형 활성화 함수를 통해 복잡한 패턴을 학습한다.

신경망의 장점은 충분한 데이터가 있을 때 사람이 직접 설계하기 어려운 복잡한 결정 경계를 학습할 수 있다는 점이다. 그러나 데이터 수가 충분하지 않거나 클래스 불균형이 존재할 경우 과적합이 발생할 수 있다.

7.2. Random Forest

Random Forest는 여러 개의 결정 트리를 만들고, 각 트리의 예측 결과를 종합하여 최종 분류를 수행하는 모델이다. 각 트리는 데이터를 서로 다른 방식으로 분할하며, 최종 결과는 다수결을 통해 결정된다.

Random Forest는 상대적으로 작은 데이터셋에서도 안정적으로 작동하는 장점이 있다. 또한 feature 기반 분류 문제에서 좋은 성능을 보이는 경우가 많다.

모델 비교 관점

Neural Network는 복잡한 패턴을 학습할 수 있지만 충분한 데이터가 필요하다. 반면 Random Forest는 비교적 작은 데이터셋에서도 안정적으로 작동하며, feature 수가 많지 않은 분류 문제에 적합하다.

8. 연구 결과

본 연구에서는 총 1,264곡의 데이터를 사용하였고, 각 곡은 8개의 오디오 feature로 표현되었다. Neural Network와 Random Forest를 적용한 결과는 다음과 같다.

Table 3: 모델별 분류 정확도

모델	정확도
Neural Network	약 75%
Random Forest	약 80%

결과적으로 Random Forest가 Neural Network보다 더 높은 정확도를 보였다. 이는 데이터 규모가 크지 않고 feature 수가 8개로 제한된 상황에서는, 복잡한 신경망보다 Random Forest와 같은 classic machine learning 모델이 더 안정적으로 작동할 수 있음을 보여준다.

또한 이 결과는 FFT와 STFT 기반 spectral feature만으로도 Boombap과 G-Funk 사이의 차이를 어느 정도 포착할 수 있음을 보여준다. 즉, 두 장르의 청각적 차이가 단순한 감각적 차이에 그치지 않고, 주파수 기반 feature를 통해 수치적으로 표현될 수 있음을 확인하였다.

9. 한계점 및 개선 방안

9.1. 기존 Feature 사용

본 연구에서는 일반적으로 많이 사용되는 spectral feature를 사용하였다. 이는 MIR에서 널리 사용되는 feature의 의미를 이해하는 데에는 효과적이었지만, 연구자가 직접 새로운 feature를 설계한 것은 아니었다.

따라서 향후 연구에서는 힙합 장르의 특성을 더 잘 반영할 수 있는 feature를 직접 설계할 필요가 있다. 예를 들어 킥과 스네어의 간격, 하이햇 밀도, 베이스 지속성, 샘플 반복성 등은 힙합 장르 분류에서 중요한 요소가 될 수 있다.

9.2. 데이터 불균형

Boombap 데이터에 비해 G-Funk 데이터가 상대적으로 부족했다. 이러한 데이터 불균형은 모델이 특정 클래스에 편향되도록 만들 수 있다.

이를 개선하기 위해서는 G-Funk 데이터를 추가로 수집하거나, 데이터 밸런싱 기법을 적용할 수 있다. 예를 들어 검색 키워드를 완화하여 더 많은 G-Funk 트랙을 수집하거나, oversampling 및 class weight 조정을 적용할 수 있다.

9.3. 모델 최적화 부족

본 연구는 feature의 DSP적 의미를 이해하는 데 초점을 맞추었기 때문에, 머신러닝 모델 자체의 최적화는 충분히 깊게 다루지 못했다. 향후에는 hyperparameter tuning, cross validation, feature selection 등을 적용하여 분류 성능을 더 높일 수 있다.

10. 연구 의의

본 연구의 가장 큰 의의는 MIR에서 사용하는 오디오 feature를 DSP 관점에서 이해했다는 점이다. 기존 MIR 연구가 음악 추천과 데이터 분석의 전체적인 흐름을 이해하는 단계였다면, 이번 연구는 오디오 feature가 실제로 어떤 신호처리 과정을 통해 계산되는지 분석한 연구였다.

특히 Boombap과 G-Funk의 차이를 단순히 감각적으로 설명하는 것이 아니라, Spectral Centroid, Spectral Bandwidth, Spectral Flux, 저역 및 고역 에너지 비율 등의 feature로 정량화하려고 했다는 점에서 의미가 있다.

즉, 본 연구는 다음과 같은 흐름을 가진다.

음악 신호 → FFT/STFT → 오디오 Feature → 머신러닝 분류 → MIR 응용

이러한 흐름은 향후 추천 시스템, 플레이리스트 자동 생성, 장르 기반 음악 분석 등으로 확장될 수 있다.

11. 향후 연구 방향

11.1. 다른 힙합 서브장르로 확장

향후에는 Boombap과 G-Funk뿐만 아니라 Trap, Jazz Rap, Memphis Rap, Experimental Hip-Hop 등 다양한 힙합 서브장르로 데이터를 확장할 수 있다. 이를 통해 힙합 내부의 세부적인 스타일 차이를 더 정밀하게 분석할 수 있다.

11.2. 직접 Feature 설계

기존 spectral feature만 사용하는 것이 아니라, 힙합 장르의 특성을 반영한 feature를 직접 설계할 수 있다. 예를 들어 다음과 같은 feature를 고려할 수 있다.

- Kick-Snare Interval
- Hi-hat Density
- Bass Continuity
- Sample Repetition Rate
- Groove Stability
- Drum Transient Strength

이러한 feature들은 단순한 주파수 정보뿐만 아니라 힙합 특유의 리듬과 그루브를 반영할 수 있다.

11.3. 추천 시스템으로의 응용

장르 분류 모델은 최종적으로 추천 시스템으로 확장될 수 있다. 각 곡을 feature vector로 표현하면, 곡 사이의 유사도를 계산할 수 있고, 이를 바탕으로 비슷한 분위기의 곡을 추천할 수 있다.

11.4. TDA 기반 MIR로 확장

다음 단계에서는 TDA, 즉 Topological Data Analysis를 MIR에 적용할 수 있다. 시간축에 따른 오디오 feature의 변화를 하나의 형태로 보고, 그 형태의 연속성이나 구조를 분석한다면 기존 머신러닝 모델과는 다른 방식의 음악 분류 및 추천 시스템을 설계할 수 있다.

예를 들어 시간에 따른 spectral feature의 변화를 point cloud로 표현하고, persistent homology를 적용하면 곡의 구조적 특징을 위상수학적으로 분석할 수 있다.

12. 결론

본 연구에서는 90년대 힙합 서브장르인 Boombap과 G-Funk를 대상으로, Apple Music 미리듣기 오디오에서 DSP 기반 feature를 추출하고 머신러닝으로 장르를 분류하였다.

FFT와 STFT를 통해 음악 신호를 주파수 영역 및 시간-주파수 영역으로 변환하였고, 이를 바탕으로 Spectral Centroid, Spectral Bandwidth, Spectral Flatness, Spectral Flux, Low-Frequency Energy Ratio, High-Frequency Energy Ratio 등 총 8개의 feature를 추출하였다.

분류 모델로는 Neural Network와 Random Forest를 비교하였으며, Random Forest가 약 80%의 정확도로 더 좋은 성능을 보였다. 이는 제한된 데이터 환경에서는 복잡한 신경망보다 classic machine learning 모델이 더 안정적으로 작동할 수 있음을 보여준다.

이 연구를 통해 MIR에서 사용되는 feature들이 단순한 수치가 아니라 DSP 기반의 수학적 표현임을 이해할 수 있었다. 또한 힙합 장르의 청각적 차이를 수치화하고, 이를 머신러닝 모델에 적용하여 자동 분류할 수 있음을 확인하였다.

향후에는 직접 feature를 설계하고, 다양한 힙합 서브장르로 확장하며, 최종적으로는 플레이리스트 추천 시스템과 TDA 기반 MIR 연구로 발전시키고자 한다.

참고 문헌

- Transnational College of LEX, 수학으로 배우는 파동의 법칙.
- S-Curt MIR with DSP 최종 연구보고서.
- S-Curt MIR with DSP 발표 자료.