

인공지능기초: 세종시 인바디 데이터 예측

1 프로젝트 개요

본 프로젝트는 세종시 인바디 측정 데이터를 이용하여 미지의 신체 지표 값을 예측하는 것을 목표로 한 인공지능기초 기말 프로젝트이다. 주어진 학습 데이터는 33개의 입력 변수와 4개의 출력 변수로 구성되어 있으며, 학습 데이터를 바탕으로 제출용 데이터의 y_1, y_2, y_3, y_4 값을 예측해야 한다.

본 프로젝트의 핵심은 하나의 데이터셋 안에 분류 문제와 회귀 문제가 함께 포함되어 있다는 점이다. 따라서 모든 target을 동일한 방식으로 처리하지 않고, 각 target의 성격에 따라 서로 다른 모델을 적용하였다. y_1 과 y_2 는 0 또는 1의 값을 가지는 이진 분류 문제로 판단하였고, y_3 와 y_4 는 연속적인 값을 예측하는 회귀 문제로 판단하였다.

$$y_1, y_2 : \text{Classification}$$

$$y_3, y_4 : \text{Regression}$$

이를 통해 본 프로젝트는 단순한 예측 과제를 넘어, 데이터의 형태에 따라 적절한 모델을 선택하고 적용하는 기본적인 머신러닝 파이프라인을 구성하는 데 의의가 있다.

2 문제 상황

주어진 데이터는 세종시 인바디 측정 결과를 기반으로 한다. 입력 변수는 총 33개이며, 신체 구성과 관련된 여러 수치형 feature들로 이루어져 있다. 대표적으로 체중, 체수분, 단백질, 무기질, 체지방량, 근육량, 골격근량, 체질량지수, 체지방률, 기초대사량, 복부지방률, 내장지방레벨 등이 포함된다.

본 프로젝트에서 해결해야 할 문제는 다음과 같이 정리할 수 있다.

$$X \in \mathbb{R}^{n \times 33}$$

$$Y = (y_1, y_2, y_3, y_4)$$

여기서 X 는 인바디 feature로 구성된 입력 행렬이고, Y 는 예측해야 하는 target variable이다. 즉, 본 프로젝트의 목표는 다음과 같은 함수 관계를 학습하는 것이다.

$$f : X \rightarrow Y$$

하지만 Y 의 각 성분은 서로 다른 성격을 가지므로, 하나의 모델로 모든 값을 한 번에 예측하기 보다 네 개의 독립적인 예측 문제로 나누어 접근하였다.

$$f_1 : X \rightarrow y_1$$

$$f_2 : X \rightarrow y_2$$

$$f_3 : X \rightarrow y_3$$

$$f_4 : X \rightarrow y_4$$

3 접근 방법

본 프로젝트에서는 복잡한 딥러닝 모델을 사용하는 대신, 인공지능기초 수업에서 다룬 기본적인 지도학습 모델을 직접 구현하는 방향으로 접근하였다. 분류 문제에는 Logistic Regression을 사용하였고, 회귀 문제에는 Linear Regression을 사용하였다.

전체적인 접근 과정은 다음과 같다.

1. 학습용 데이터와 제출용 데이터를 불러온다.
2. 학습 데이터에서 입력 변수와 target variable을 분리한다.
3. 입력 변수의 scale 차이를 줄이기 위해 표준화를 수행한다.
4. y_1, y_2 는 Logistic Regression으로 학습한다.
5. y_3, y_4 는 Linear Regression으로 학습한다.
6. 학습된 모델을 제출용 데이터에 적용하여 target 값을 예측한다.
7. 예측 결과를 제출용 파일에 저장한다.

4 데이터 전처리

인바디 데이터의 feature들은 서로 다른 단위와 범위를 가진다. 예를 들어 체중, 체지방률, 기초대사량, 복부둘레는 모두 값의 크기와 단위가 다르다. 이러한 차이는 모델 학습 과정에서 특정 feature가 과도하게 큰 영향을 주는 원인이 될 수 있다.

따라서 본 프로젝트에서는 입력 변수에 대해 표준화를 적용하였다. 표준화는 각 feature에서 평균을 빼고 표준편차로 나누는 방식이다.

$$X_{\text{std}} = \frac{X - \mu}{\sigma}$$

여기서 μ 는 학습 데이터의 평균이고, σ 는 학습 데이터의 표준편차이다. 제출용 데이터 역시 같은 기준으로 변환해야 하므로, 제출용 데이터의 평균과 표준편차를 새로 계산하지 않고 학습 데이터에서 계산한 μ 와 σ 를 사용하였다.

$$X_{\text{sub,std}} = \frac{X_{\text{sub}} - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

이 과정을 통해 학습 데이터와 제출용 데이터가 동일한 scale 기준 위에서 모델에 입력되도록 하였다.

5 분류 모델

y_1 과 y_2 는 이진 분류 문제로 판단하였다. 따라서 두 target에 대해서는 Logistic Regression을 사용하였다. Logistic Regression은 입력 변수의 선형 결합을 계산한 뒤, 이를 sigmoid function에 통과시켜 0과 1 사이의 확률값으로 변환하는 모델이다.

먼저 입력 벡터 x 에 대해 다음과 같은 선형 결합을 계산한다.

$$z = \theta^T x$$

이후 sigmoid function을 적용한다.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

따라서 모델의 출력은 다음과 같이 표현된다.

$$h_{\theta}(x) = \sigma(\theta^T x)$$

여기서 $h_{\theta}(x)$ 는 해당 데이터가 class 1에 속할 확률로 해석할 수 있다. 최종 예측값은 threshold 0.5를 기준으로 결정하였다.

$$\hat{y} = \begin{cases} 1, & h_{\theta}(x) \geq 0.5 \\ 0, & h_{\theta}(x) < 0.5 \end{cases}$$

Logistic Regression의 parameter θ 는 Gradient Descent를 이용하여 학습하였다. 학습 데이터의 개수를 m 이라고 할 때, update rule은 다음과 같다.

$$\theta := \theta - \alpha \frac{1}{m} X^T (h_{\theta}(X) - y)$$

여기서 α 는 learning rate이다. 본 프로젝트에서는 반복적인 parameter update를 통해 y_1 과 y_2 에 대한 두 개의 분류 모델을 각각 학습하였다.

6 회귀 모델

y_3 와 y_4 는 연속적인 값을 예측해야 하는 문제로 판단하였다. 따라서 두 target에 대해서는 Linear Regression을 사용하였다.

Linear Regression은 입력 변수들의 선형 결합을 통해 target value를 예측하는 모델이다.

$$\hat{y} = \theta^T x$$

전체 데이터에 대해 matrix form으로 표현하면 다음과 같다.

$$\hat{Y} = X\theta$$

Linear Regression의 목표는 예측값과 실제값 사이의 차이를 최소화하는 parameter θ 를 찾는 것이다. 이는 다음과 같은 least squares problem으로 표현된다.

$$\min_{\theta} \|X\theta - y\|^2$$

Normal Equation을 사용하면 parameter는 다음과 같이 계산할 수 있다.

$$\theta = (X^T X)^{-1} X^T y$$

하지만 실제 데이터에서는 $X^T X$ 가 역행렬을 가지지 않거나 수치적으로 불안정할 수 있다. 따라서 본 프로젝트에서는 pseudo-inverse를 사용하여 parameter를 계산하였다.

$$\theta = (X^T X)^+ X^T y$$

이를 통해 회귀 모델이 보다 안정적으로 parameter를 계산할 수 있도록 하였다.

7 모델 구조

본 프로젝트의 전체 모델 구조는 다음과 같이 정리할 수 있다.

$$X_{\text{train}} \rightarrow \text{Standardization} \rightarrow X_{\text{train,std}}$$

$$X_{\text{sub}} \rightarrow \text{Standardization} \rightarrow X_{\text{sub,std}}$$

분류 target에 대해서는 다음과 같은 모델을 학습하였다.

$$X_{\text{train,std}} \rightarrow f_1 \rightarrow \hat{y}_1$$

$$X_{\text{train,std}} \rightarrow f_2 \rightarrow \hat{y}_2$$

회귀 target에 대해서는 다음과 같은 모델을 학습하였다.

$$X_{\text{train,std}} \rightarrow f_3 \rightarrow \hat{y}_3$$

$$X_{\text{train,std}} \rightarrow f_4 \rightarrow \hat{y}_4$$

최종적으로 제출용 데이터에 대해 다음과 같은 예측 결과를 생성하였다.

$$X_{\text{sub,std}} \rightarrow (\hat{y}_1, \hat{y}_2, \hat{y}_3, \hat{y}_4)$$

8 구현 흐름

본 프로젝트의 구현 흐름은 다음과 같다.

1. 데이터 불러오기

학습용 Excel 파일과 제출용 Excel 파일을 불러온다.

2. 입력 변수와 출력 변수 분리

학습 데이터에서 y_1, y_2, y_3, y_4 column을 target variable로 분리하고, 나머지 column을 input feature로 사용한다.

3. 표준화

학습 데이터의 평균과 표준편차를 계산한 뒤, 학습 데이터와 제출용 데이터에 동일하게 적용한다.

4. 분류 모델 학습

y_1 과 y_2 에 대해 각각 Logistic Regression을 학습한다.

5. 회귀 모델 학습

y_3 와 y_4 에 대해 각각 Linear Regression을 학습한다.

6. 예측 수행

학습된 네 개의 모델을 제출용 데이터에 적용하여 target 값을 예측한다.

7. 결과 저장

예측된 y_1, y_2, y_3, y_4 값을 제출용 파일에 입력하여 최종 제출 파일을 생성한다.

9 결과

본 프로젝트에서는 제출용 데이터에 대해 네 개의 target variable을 예측하였다. y_1 과 y_2 는 Logistic Regression을 통해 0 또는 1의 class label로 예측되었다. y_3 와 y_4 는 Linear Regression을 통해 연속적인 실수값으로 예측되었다.

최종 output은 다음과 같은 형태를 가진다.

$$\hat{Y}_{\text{sub}} = (\hat{y}_1, \hat{y}_2, \hat{y}_3, \hat{y}_4)$$

즉, 제출용 데이터의 각 sample에 대해 네 개의 target 값을 예측하고, 이를 제출 파일의 해당 column에 저장하였다.

10 한계점

본 프로젝트에는 다음과 같은 한계가 존재한다.

10.1 모델의 단순성

본 프로젝트에서는 Logistic Regression과 Linear Regression만 사용하였다. 두 모델은 해석이 쉽고 구현이 간단하다는 장점이 있지만, 입력 변수와 target variable 사이의 복잡한 비선형 관계를 충분히 반영하기 어렵다. 인바디 데이터는 여러 신체 지표가 서로 복합적으로 연결되어 있기 때문에, 실제 관계는 단순한 선형 관계보다 더 복잡할 가능성이 있다.

10.2 검증 과정의 부족

학습 데이터를 별도의 validation set으로 나누어 성능을 평가하지 않았다. 따라서 모델이 실제로 어느 정도의 예측 성능을 가지는지 정량적으로 확인하지 못했다. 이는 제출용 데이터에 대해 예측값을 생성하는 데에는 문제가 없지만, 모델의 일반화 성능을 판단하기에는 한계가 있다.

10.3 Regularization 미적용

인바디 feature들은 서로 높은 상관관계를 가질 가능성이 있다. 예를 들어 체중, 근육량, 제지방량, 골격근량 등은 독립적인 변수라기보다 서로 강하게 연결된 변수일 수 있다. 이 경우 multicollinearity 문제가 발생할 수 있지만, 본 프로젝트에서는 Ridge Regression이나 Lasso Regression과 같은 regularization 기법을 적용하지 않았다.

10.4 y_4 예측에서 8 Centers 데이터 미활용

과제 안내에서는 y_4 예측에 대해 8 centers 데이터를 활용하는 것을 권장하였다. 그러나 본 프로젝트의 최종 구현에서는 8 centers 데이터를 직접 활용하지 못하고, y_4 역시 Linear Regression으로 예측하였다. 만약 y_4 가 특정 center와의 거리 또는 cluster 구조와 관련된 값이라면, 본 모델은 해당 구조적 정보를 충분히 반영하지 못했을 가능성이 있다.

10.5 Feature Selection 미수행

본 프로젝트에서는 주어진 33개의 input feature를 모두 사용하였다. 하지만 모든 feature가 target 예측에 동일하게 중요한 것은 아니다. 일부 feature는 예측에 거의 영향을 주지 않거나 오히려 noise로 작용했을 수 있다. 따라서 feature selection을 수행하지 못한 점도 한계로 볼 수 있다.

11 개선 방향

본 프로젝트는 기본적인 머신러닝 모델을 이용하여 제출용 데이터를 예측하는 데 초점을 두었지만, 다음과 같은 방식으로 개선할 수 있다.

1. 학습 데이터를 train set과 validation set으로 나누어 모델 성능을 정량적으로 평가한다.
2. Logistic Regression과 Linear Regression 외에 Decision Tree, Random Forest, Support Vector Machine 등의 모델을 비교한다.
3. Ridge Regression이나 Lasso Regression을 적용하여 overfitting과 multicollinearity 문제를 완화한다.

4. y_4 예측에서는 8 centers 데이터를 활용하여 각 sample과 center 사이의 거리를 새로운 feature로 추가한다.
5. Feature correlation analysis를 통해 target과 관련성이 높은 feature를 선별한다.
6. Classification target과 Regression target을 분리하여 각각에 맞는 평가 지표를 사용한다.

12 프로젝트 의의

본 프로젝트는 실제 신체 측정 데이터를 바탕으로 classification과 regression을 모두 다루었다는 점에서 의미가 있다. 특히 하나의 데이터셋 안에서도 target variable의 성격에 따라 서로 다른 모델을 선택해야 한다는 점을 확인할 수 있었다.

또한 본 프로젝트에서는 머신러닝 라이브러리의 모델을 단순히 호출하는 대신, Logistic Regression의 Gradient Descent와 Linear Regression의 Normal Equation을 직접 구현하는 방식으로 접근하였다. 이를 통해 모델이 내부적으로 어떤 수학적 구조를 가지는지 이해할 수 있었다.

결과적으로 본 프로젝트는 인공지능기초 수업에서 배운 지도학습의 기본 개념을 실제 데이터에 적용한 사례이며, 이후 의료 데이터 분석, 신체 데이터 예측, 추천 시스템, clustering 기반 분석 등으로 확장될 수 있는 기초 프로젝트라고 할 수 있다.